Corso di Laurea Magistrale in Data Science

Computer Vision

A.A. 2025-2026

Privacy-Preserving Autonomous Driving con YOLOv9

Professore Donato Impedovo
Studente Emanuele Piemontese

Emanuele Piemontese

837858

e.piemontese@studenti.uniba.it

INDICE

1. Introduzione 3
1.1 Contesto 3
1.2 Problema 3
2. Lavori correlati (State of the Art) 4
2.1 Il Dataset PP4AV 4
2.2 Il modello Baseline e risultati 4
2.3 L'evoluzione della famiglia YOLO e la scelta di YOLOv9 6
3. Panoramica del progetto 8
3.1 Domanda di ricerca 8
3.2 Obiettivi 8
4. Analisi Esplorativa dei Dati (EDA) 10
4.1 Dimensioni e sbilanciamento delle classi 10
4.2 Risoluzione e sfide di Small Object Detection 11
4.3 Anomalia nei dati: il caso limite dell'Area Volto 11
5. Sperimentazione 1 12
5.1 Primo ciclo sperimentale 12
Fase 1: Preparazione e Splitting del Dataset 13
Fase 2: Fine-Tuning 14
Fase 3: Inferenza e Valutazione delle metriche 19
5.2 Secondo ciclo sperimentale 23
Fase 1: Ribilanciamento del Dataset 23
Fase 2: Fine-Tuning 24
Fase 3: Inferenza e Valutazione delle metriche 28
6. Confronto: Baseline, Ciclo sperimentale 1 e Ciclo sperimentale 2 33
7. Sperimentazione 2: Approccio Data-Centric 35
Fase 1: Generazione sintetica e bilanciamento del Dataset 35
Fase 2: Fine-Tuning 37
Fase 3: Inferenza e Valutazione delle metriche 37
8. Risultati Finali: Impatto dell'approccio Data-Centric 38
Conclusioni 40

1. Introduzione

1.1 Contesto

Lo **sviluppo** dei moderni **sistemi di guida autonoma** si basa, quasi interamente, sull'addestramento di **reti neurali profonde** alimentate da **enormi quantità di dati visivi**.

Tuttavia, raccogliere video e immagini sulle **strade pubbliche** significa catturare inevitabilmente un'**infinità di dati sensibili**, come **volti dei pedoni** e **targhe dei veicoli**.

Con l'avvento di normative sempre più stringenti sulla protezione dei dati, come il **GDPR** (General Data Protection Regulation) in Europa, la tutela della privacy è diventata un pilastro fondamentale della ricerca tecnologica.

Oggi, l'**anonimizzazione dei dati** non è più vista solo come una buona pratica etica, ma rappresenta un vincolo legale stringente. Prima che un qualsiasi dataset di guida autonoma possa essere utilizzato per la ricerca, archiviato o condiviso, è diventato tassativo applicare algoritmi di *Computer Vision* capaci di oscurare queste informazioni personali in modo automatico e affidabile.

1.2 Problema

Se il **rilevamento di un volto** o **di una targa** in condizioni ideali (in pieno giorno, con buona risoluzione e frontalmente) è un problema ampiamente risolto, la realtà su strada è ben diversa e decisamente più caotica.

Il **vero tallone d'Achille** degli attuali modelli di anonimizzazione emerge quando si scontrano con i cosiddetti "*corner cases*", ovvero **scenari di guida complessi e non standard**.

Da un lato, i veicoli a guida autonoma fanno largo uso di **telecamere con lenti grandangolari** o **fisheye** per massimizzare il campo visivo a 360 gradi. Questo tipo di ottica introduce distorsioni radiali molto forti, curvando le linee e alterando le proporzioni degli oggetti, soprattutto ai bordi dell'inquadratura.

Dall'altro lato, le **variazioni ambientali estreme**, come la guida notturna o in condizioni di scarsa illuminazione, riducono drasticamente la visibilità dei dettagli.

I **modelli** di rilevamento più **tradizionali**, essendo spesso addestrati su dataset composti da immagini "perfette" e rettilinee, **tendono a fallire** proprio in queste situazioni critiche, mancando il bersaglio e lasciando esposti i dati sensibili.

2. Lavori correlati (State of the Art)

2.1 Il Dataset PP4AV

Il punto di partenza fondamentale di questo progetto è il lavoro di Trinh et al. (2023), "**PP4AV: A Benchmarking Dataset for Privacy-preserving Autonomous Driving**".

Prima di questa pubblicazione, la comunità scientifica **mancava** di **un dataset pubblico** specificamente costruito per **valutare le prestazioni dei modelli di anonimizzazione** (oscuramento di volti e targhe) in contesti di guida reali. Spesso si utilizzavano dataset generici (come WIDER Face per i volti o CCPD per le targhe), che non riflettono le reali sfide prospettiche e ambientali di una telecamera montata su un veicolo in movimento.
Per colmare questa lacuna, gli autori hanno creato **PP4AV** (Privacy-Preserving for Autonomous Vehicles), un dataset di **3.447 immagini annotate**.

La sua forza risiede nella rappresentatività degli scenari. Le **immagini** sono state **campionate da video** di guida in **sei diverse città europee** (Parigi, Zurigo, Strasburgo, Stoccarda, Svizzera e Paesi Bassi).
Oltre alle condizioni diurne standard, il dataset introduce **scenari complessi**:

- **guida notturna:** il sotto-insieme *Netherlands_night* (824 immagini) presenta forti sfide legate a bassa illuminazione, fari abbaglianti e rumore visivo.
- **distorsione ottica:** il sotto-insieme *Fisheye* (244 immagini), derivato dal dataset WoodScape, introduce telecamere a 360 gradi. Queste lenti massimizzano il campo visivo ma generano una grave distorsione radiale, alterando la geometria e le proporzioni degli oggetti ai bordi dell'inquadratura.

2.2 Il modello Baseline e risultati

Come architettura di riferimento gli autori hanno scelto **YOLOX**, un modello di rilevamento oggetti *anchor-free* noto per il suo eccellente compromesso tra velocità di inferenza e accuratezza.
L'aspetto più critico del loro lavoro riguarda il metodo di addestramento. Per addestrare YOLOX, i ricercatori hanno adottato una complessa tecnica di "**Knowledge Distillation**" (Distillazione della Conoscenza) combinata con "**Pseudo-Labeling**" su enormi moli di video di guida oltre al dataset PP4AV.
In questa architettura Insegnante-Studente, hanno utilizzato **modelli iperspecializzati** e **massicci** come "Teacher" (YOLO5Face per i volti, pre-addestrato su WIDER FACE, e sistemi commerciali

avanzati per le targhe). Questi modelli generavano etichette sintetiche sui video grezzi, che venivano poi utilizzate per istruire il modello YOLOX ("Student"). Di conseguenza, la baseline YOLOX possiede un'esperienza visiva (inclusiva di distorsioni grandangolari) enormemente superiore rispetto a quella contenuta nel solo PP4AV.

Le due metriche fondamentali impiegate per quantificare il successo di YOLOX sono l'**Average Precision (AP)** e l'**Average Recall (AR)**, entrambe vincolate a una specifica soglia geometrica denominata **IoU**.

L'**IoU** (Intersection over Union) è una misura geometrica che **valuta l'esattezza spaziale della predizione**, calcolando il grado di sovrapposizione tra il *bounding box* predetto dalla rete e il *bounding box* reale tracciato dall'annotatore umano (la "Ground Truth").

Matematicamente si esprime come:

$$\text{IoU} = \frac{\text{Area di Intersezione}}{\text{Area di Unione}}$$

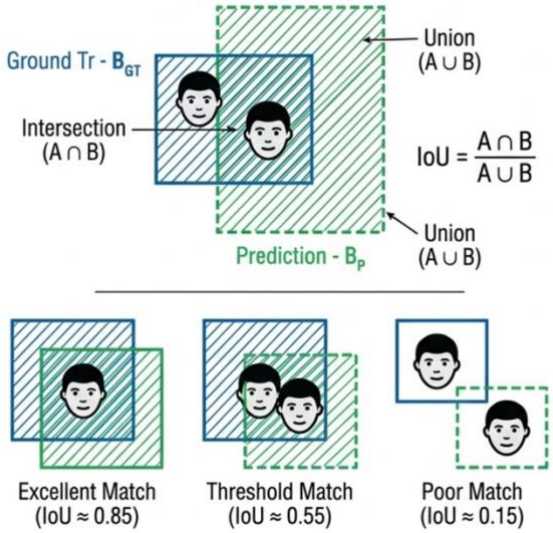

La notazione **0.50** presente nelle metriche (come in AP_0.50 e AR_0.50) indica la soglia minima di tolleranza spaziale: una predizione viene considerata corretta (Vero Positivo) solo ed esclusivamente se il suo *bounding box* si sovrappone per almeno il 50% (IoU >= 0.50) all"oggetto reale.

L'**Average Precision (AP)** è l'indicatore principale per valutare l'accuratezza clinica del modello e sintetizza matematicamente l'area sottesa alla curva *Precision-Recall*.

Questa metrica risponde alla domanda:

"Di tutti gli oggetti che il modello ha dichiarato di aver trovato, quanti erano realmente corretti?".

Un'elevata AP indica che il modello è estremamente preciso e genera pochissimi **Falsi Positivi** (non è affetto da "allucinazioni" algoritmiche).

Esempio nel progetto: immaginiamo che, durante l'elaborazione di un frame sferico, il modello tracci 10 *bounding box* assegnandoli alla classe "Targa". Se 8 di questi rettangoli delimitano effettivamente delle targhe reali (con IoU >= 0.50) mentre gli altri 2 inquadrano per errore la texture dell'asfalto, la precisione in quello scenario è dell"80%.

L'**Average Recall (AR)** è la metrica complementare all'AP e misura la completezza, la sensibilità e la capacità di esplorazione visiva del modello.

Questa metrica risponde alla domanda:

"Di tutti gli oggetti fisicamente presenti nella scena, quanti ne sono stati effettivamente intercettati dal modello?".

Un alto Recall significa che la rete neurale genera pochissimi **Falsi Negativi** e non "ignora" bersagli presenti nell'inquadratura.

Esempio nel progetto: se ai bordi estremi di un'immagine *fisheye* sono presenti 10 volti pesantemente distorti dalla lente, e il modello riesce a rilevarne e delimitarne correttamente solo 6 (mancandone 4, che passano inosservati), il Recall si attesta al 60%. In ambiti critici come la percezione per i veicoli a guida autonoma, massimizzare il Recall è di vitale importanza: ignorare un pedone reale (Falso Negativo) è un errore sistemico molto più pericoloso rispetto a rilevare un ostacolo fittizio (Falso Positivo).

Valutando il modello YOLOX gli autori hanno registrato i seguenti **risultati**:

	Normal images		Fisheye images	
Classe	**AP_0.5**	**AR_0.5**	**AP_0.5**	**AR_0.5**
Face	76.22%	92.52%	59.20%	63.92%
Plate	88.12%	91.88%	49.53%	58.17%

Sebbene le metriche di *Average Precision* (AP) e *Average Recall* (AR) si mantengano su livelli accettabili per le immagini diurne urbane standard, si osserva un **drastico degrado delle prestazioni** nei cosiddetti **corner cases**.

2.3 L'evoluzione della famiglia YOLO e la scelta di YOLOv9

L'elaborazione delle immagini nel campo della guida autonoma richiede algoritmi capaci di bilanciare un'elevata accuratezza geometrica con tempi di inferenza in tempo reale. In questo panorama, la famiglia di reti neurali **YOLO ("You Only Look Once")** rappresenta lo stato dell'arte per le architetture a singolo stadio ("single-stage detectors").

Prima dell'introduzione di YOLO, i sistemi di visione artificiale si basavano su approcci a due stadi (come R-CNN), che prima estraevano le regioni di interesse e successivamente le classificavano, risultando computazionalmente lenti. YOLO ha rivoluzionato l'approccio matematico all'"Object Detection" trasformandolo in un **singolo problema di regressione**.

Invece di analizzare l'immagine in più passaggi, un modello **YOLO analizza l'intero fotogramma** in un singolo passaggio (da qui il nome "You Only Look Once").
L'immagine in input viene divisa in una **griglia spaziale** ($S \times S$). Se il centro di un oggetto cade all'interno di una cella della griglia, quella specifica cella diventa responsabile del rilevamento dell'oggetto. Ogni cella predice contemporaneamente le coordinate spaziali dei **bounding box**, il livello di confidenza ("Confidence Score") e le probabilità della classe di appartenenza.
Questa elaborazione unificata permette a YOLO di ragionare sul contesto globale dell'immagine, riducendo i falsi positivi sui background e garantendo velocità operative compatibili con i rigidi requisiti *real-time* del settore automotive.

YOLOX, rilasciato nel 2021, rappresenta un punto di svolta fondamentale nella famiglia YOLO ed è stato scelto dagli autori del dataset PP4AV come modello di riferimento (Baseline). La sua importanza storica e ingegneristica risiede nell'introduzione di tre innovazioni strutturali:

- **Approccio "Anchor-Free":** a differenza dei predecessori che utilizzavano "anchor box" predefinite (scatole di dimensioni fisse usate come riferimento), YOLOX predice direttamente le dimensioni degli oggetti. Questo elimina la necessità di calibrare manualmente le ancore prima dell'addestramento, rendendo il modello molto più flessibile nell'individuare oggetti di forme insolite o, come nel caso del dominio "Fisheye", pesantemente distorti dalla prospettiva.
- **"Decoupled Head" (Testa Disaccoppiata):** YOLOX separa matematicamente il calcolo della classificazione (capire "cosa" è l'oggetto) dal calcolo della regressione (capire "dove" si trova l'oggetto). Questa separazione risolve un noto conflitto nei gradienti durante l'addestramento, migliorando significativamente sia la precisione spaziale sia la convergenza del modello.
- **"SimOTA" (Label Assignment):** introduce un algoritmo avanzato per assegnare in modo dinamico le etichette di "Ground Truth" alle predizioni, ottimizzando il modo in cui la rete impara a distinguere oggetti sovrapposti o raggruppati.

Rilasciato all'inizio del 2024, **YOLOv9** rappresenta l'attuale vertice dell'ingegnerizzazione per le reti "single-stage". Il team di sviluppo ha affrontato e risolto uno dei problemi fisici più complessi del "Deep Learning": l'**"Information Bottleneck"** (collo di bottiglia dell'informazione).
Man mano che un'immagine attraversa i numerosi strati ("layers") di una rete neurale profonda, parte dell'informazione originale (i dettagli dei pixel) viene inevitabilmente persa o degradata. Per risolvere questo limite, YOLOv9 introduce due innovazioni architetturali dirompenti:

- **PGI ("Programmable Gradient Information"):** è un meccanismo matematico rivoluzionario che fornisce gradienti affidabili e "puliti" durante l'addestramento (tramite un ramo ausiliario

reversibile). Il PGI garantisce che la rete non "dimentichi" le caratteristiche spaziali cruciali dell'immagine originale, anche dopo decine di passaggi convoluzionali. Questo è vitale per l'analisi di immagini sferiche, dove i dettagli dei volti ai bordi sono già compressi dalla distorsione ottica e non possono subire ulteriori perdite di informazione.

- **GELAN ("Generalized Efficient Layer Aggregation Network"):** è un nuovo blocco architetturale progettato per massimizzare l'efficienza dei parametri. GELAN permette a YOLOv9 di estrarre e combinare le "feature" visive in modo molto più veloce e leggero rispetto ai modelli precedenti, garantendo un'accuratezza ("Average Precision") superiore a fronte di un costo computazionale ridotto.

L'adozione di YOLOv9 in questo progetto sperimentale sfrutta l'avanzata conservazione dei gradienti (PGI) per decodificare le complesse distorsioni geometriche delle lenti "Fisheye".

3. Panoramica del progetto

3.1 Domanda di ricerca

Il presente lavoro nasce per rispondere a un quesito tecnico specifico nel dominio della *Computer Vision* applicata alla guida autonoma:

Modelli *state-of-the-art* come YOLOv9, sottoposti a un *fine-tuning* strategico, possono eguagliare o superare le metriche di *Average Precision* (AP) e *Average Recall* (AR) di una complessa baseline YOLOX, utilizzando esclusivamente la quantità limitata di immagini del dataset PP4AV, senza ricorrere a enormi moli di video esterni o a tecniche di "Knowledge Distillation"?

Si intende verificare se l'efficienza architetturale di YOLOv9 consenta di risolvere i *corner cases* legati alle distorsioni ottiche ("Fisheye") in un regime di stretta scarsità di dati (*Data Efficiency*).

3.2 Obiettivi

Per rispondere in modo esaustivo alla domanda di ricerca, il progetto è stato scomposto in quattro obiettivi primari:

1. **Valutazione del "Domain Shift" e della Generalizzazione:** indagare la capacità nativa delle moderne architetture di "Object Detection" di mantenere prestazioni stabili quando esposte a drastici cambiamenti del dominio visivo. L'obiettivo è quantificare il degrado prestazionale che si verifica passando da immagini a prospettiva lineare a scenari otticamente distorti (es. lenti grandangolari), definendo matematicamente il limite di generalizzazione "Zero-Shot" dei modelli.

2. **Analisi delle criticità nei dataset sbilanciati:** dimostrare i limiti operativi dell'approccio puramente "Model-Centric" in scenari di forte asimmetria dei dati. Si intende esplorare come la sola complessità architetturale non sia in grado di prevenire il sovradattamento ("Overfitting") sulle classi visive predominanti, portando inevitabilmente a un collasso del rilevamento sui bersagli minoritari o soggetti a severe deformazioni spaziali.
3. **Validazione del paradigma "Data-Centric":** progettare e validare una metodologia incentrata sull'ingegnerizzazione del dato per superare i limiti strutturali dei modelli. L'obiettivo è dimostrare che l'ottimizzazione del set di addestramento, ottenuta tramite la generazione sintetica mirata e il bilanciamento algoritmico, è in grado di compensare la scarsità di campioni reali nei "corner cases", migliorando la robustezza del sistema in modo più efficace rispetto alla mera alterazione dell'architettura neurale.
4. **"Benchmarking" e analisi dei compromessi prestazionali:** stabilire un rigoroso "framework" di valutazione comparativa per quantificare l'efficacia delle metodologie proposte. Lo scopo è utilizzare metriche standardizzate per analizzare i "trade-off" tra precisione clinica e capacità di copertura visiva ("Recall"), certificando il superamento delle criticità sui domini complessi senza incorrere in fenomeni di oblio catastrofico ("Catastrophic Forgetting") sui domini standard di partenza.

4. Analisi Esplorativa dei Dati (EDA)

Per **comprendere** a fondo la **complessità** del dominio visivo e **orientare le scelte** architetturali per il *fine-tuning* di YOLOv9, ho condotto un'Analisi Esplorativa dei Dati (EDA) sull'intero dataset PP4AV, estraendo informazioni da **3.447 immagini** e **11.923 annotazioni** (*bounding box*).

4.1 Dimensioni e sbilanciamento delle classi

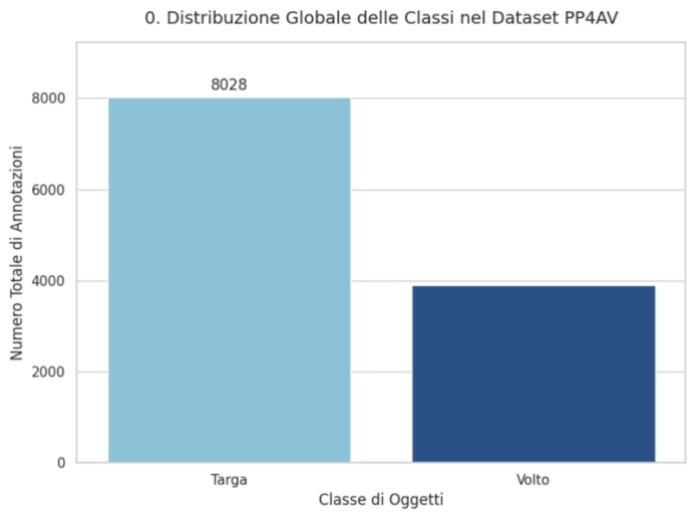

L'analisi della distribuzione delle classi rivela un **marcato sbilanciamento** intrinseco allo scenario della guida urbana: il dataset è dominato dalla classe "**Targa**", che rappresenta il **67.3%** delle annotazioni (8.028 istanze), mentre la classe "**Volto**" costituisce il restante **32.7%** (3.895 istanze).

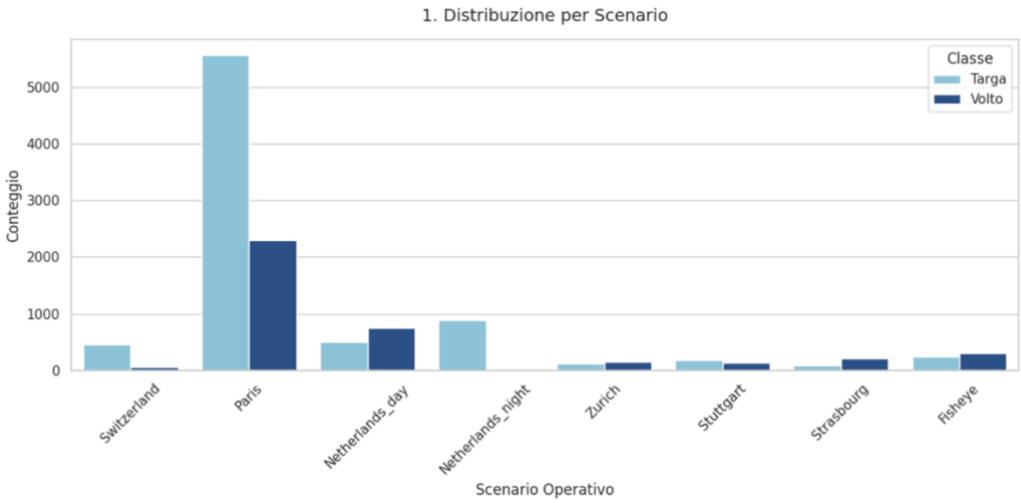

Notiamo come la **distribuzione** delle immagini nei vari paesi è **quasi identica** sia per numero che per classe, **tranne** per i paesi come **Parigi**, **Svizzera** e **Paesi Bassi**.

La densità media si attesta su **3.46 oggetti per immagine**, con picchi fino a 23 oggetti in scenari particolarmente affollati. Questo sbilanciamento impone l'utilizzo di metriche di valutazione focalizzate sulla singola classe (come l'AP per classe) piuttosto che su medie globali che potrebbero mascherare le inefficienze sulla classe minoritaria.

4.2 Risoluzione e sfide di Small Object Detection

L'**analisi delle risoluzioni** originali conferma l'eterogeneità dei sensori utilizzati:

- 1280x720: 2646 immagini (76.8%), risoluzione HD;
- 1920x1080: 388 immagini (11.3%), risoluzione Full HD;
- 1280x966: 244 immagini (7.1%);
- 2048x1024: 169 immagini (4.9%).

Il resize a `imgsz = 640`, tipico delle architetture YOLO, rappresenta quindi un **compromesso accettabile** che non degrada eccessivamente l'informazione originale, pur richiedendo l'attivazione automatica del **Letterboxing** per gestire i formati non standard (come il 1280x966).

Il **dato più critico** emerso dall'EDA riguarda l'analisi geometrica (**Area Relativa**). Per la classe "**Targa**", l'area media occupata rispetto all'intero frame è di un microscopico **0.0634%**, con valori minimi che scendono allo 0.0009%. Questo classifica inequivocabilmente il **task** come **Small Object Detection** estremo, giustificando la scelta dell'architettura YOLOv9, il cui modulo PGI è stato progettato specificamente per preservare le informazioni spaziali sui layer più profondi, evitando che feature così ridotte vengano perse durante i passaggi convoluzionali.

4.3 Anomalia nei dati: il caso limite dell'Area Volto

Le metriche geometriche della classe "Volto" hanno evidenziato un'**anomalia statistica** (Area Max: 37569.06%). Questo valore abnorme indica la presenza di **annotazioni palesemente errate** nel dataset originale, in cui il **bounding box** risulta ampiamente superiore ai bordi dell'immagine stessa. Tali **outliers** possono destabilizzare il calcolo della loss function (nella fattispecie la IoU) durante l'addestramento. La **robustezza nativa della loss di YOLO**, tuttavia, è concepita per ammortizzare l'impatto di annotazioni corrotte, senza richiedere una pulizia manuale del dataset che altererebbe il benchmark originario.

5. Sperimentazione 1

Per garantire la riproducibilità dell'esperimento e supportare la domanda di ricerca tramite uno studio logico e incrementale, il primo flusso di lavoro è stato rigorosamente strutturato in due cicli sperimentali:

- **Ciclo 1: Fine-Tuning isolato (valutazione Out-of-Distribution)**
  Il primo ciclo mira a stabilire una metrica di partenza e a testare la generalizzazione "Zero-Shot" del modello. L'architettura YOLOv9 viene addestrata esclusivamente sulle immagini stradali convenzionali ("Normal") del dataset PP4AV. Successivamente, le metriche vengono calcolate in due fasi separate: prima sul set di validazione standard e poi sul set "Fisheye" (mai osservato in fase di addestramento). L'obiettivo è quantificare il degrado prestazionale causato dalla distorsione ottica.
- **Ciclo 2: Adattamento al dominio (Mixed-Domain Training)**
  Il secondo ciclo introduce la variabile dell'adattamento ai dati per permettere un confronto "alla pari" con la baseline YOLOX. Il dataset viene strategicamente ribilanciato ricollocando l'80% delle immagini "Fisheye" all'interno del *Training Set*. Il modello viene addestrato ex-novo, consentendo ai layer convoluzionali di apprendere nativamente la deformazione radiale.

5.1 Primo ciclo sperimentale

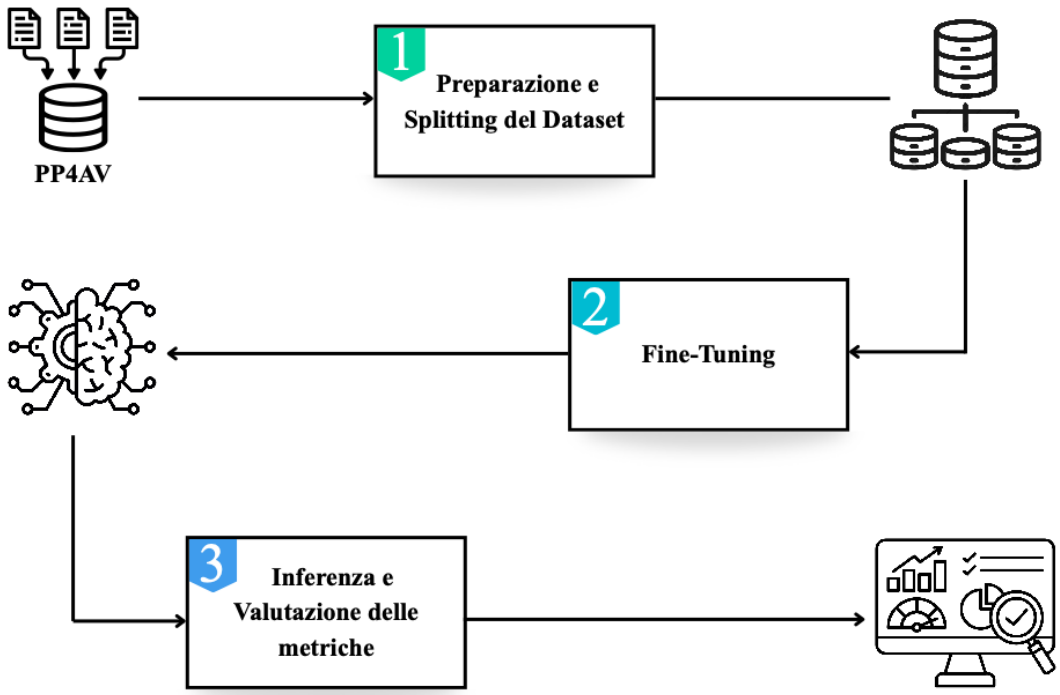

Fase 1: Preparazione e Splitting del Dataset

L'**obiettivo primario** in questa fase non è la massimizzazione assoluta delle performance, bensì la **creazione di una baseline interna** rigorosa per quantificare la capacità di generalizzazione "Zero-Shot" dell'architettura YOLOv9 di fronte a domini visivi completamente inesplorati.

Per ottenere questo risultato, è stato progettato uno split dei dati fortemente asimmetrico basato sulla geometria delle lenti di acquisizione.
Le **immagini** provenienti dalle **telecamere standard**, ovvero quelle acquisite nelle città di Zurigo, Parigi, Stoccarda, Strasburgo e l'intero set dei Paesi Bassi (sia in condizioni diurne che notturne), sono state **raggruppate per costituire il nucleo della conoscenza del modello** (In-Distribution). Questa scelta garantisce che la rete neurale apprenda le caratteristiche di volti e targhe in contesti urbani complessi, ma pur sempre caratterizzati da una prospettiva lineare.

Di contro, il **dominio "Fisheye"**, caratterizzato da telecamere a 360 gradi che introducono una severa distorsione radiale comunemente nota come "effetto barile", è stato interamente **escluso dalla fase di apprendimento**. Questa porzione del dataset è stata isolata per fungere da set di test "Out-of-Distribution" puro.

La **suddivisione** matematica, eseguita tramite uno script Python dedicato alla manipolazione dei file di testo nel formato YOLO, ha prodotto la seguente allocazione definitiva:

- **Training Set** (80%): 2561 immagini, destinate al calcolo e all'aggiornamento dei pesi della rete neurale durante la discesa del gradiente;
- **Validation Set** (10%): 318 immagini, utilizzate al termine di ogni epoca di addestramento per monitorare la funzione di perdita ("loss") su dati non visti e prevenire il fenomeno dell'overfitting".
- **Test Set "Normal"** (10%): 324 immagini, utilizzate per validare le prestazioni finali sullo stesso dominio geometrico dell'addestramento;
- **Test Set "Fisheye"**: 244 immagini, ovvero il 100% del sottoinsieme originale con lenti grandangolari.

Fase 2: Fine-Tuning

L'ambiente di addestramento è stato implementato sfruttando l'infrastruttura **cloud Kaggle**, che ha permesso l'allocazione di due acceleratori hardware **GPU NVIDIA Tesla T4**.
Il modello selezionato per l'esperimento è **YOLOv9** nella sua **variante compatta**, identificata dal file "yolov9c.pt". La scelta della versione "C" è ampiamente motivata dalla necessità di trovare il miglior compromesso tra elevata capacità estrattiva (garantita dal modulo Programmable Gradient Information) e sostenibilità computazionale in scenari di guida autonoma in tempo reale.

Gli **iperparametri** di addestramento sono stati selezionati con criteri ingegneristici precisi volti a massimizzare l'efficienza hardware.
Il parametro `epochs = 50` è stato scelto come orizzonte temporale esplorativo, sufficiente per osservare la stabilizzazione iniziale delle curve di apprendimento senza incorrere in costi computazionali eccessivi.
Per accelerare drasticamente la convergenza iniziale della rete, è stato abilitato il parametro `pretrained = True`. Questa tecnica, nota nel Deep Learning come "Transfer Learning", inizializza i filtri convoluzionali con i pesi già ottimizzati sul massivo dataset generico COCO. Questo approccio permette alla rete di riconoscere forme, ombre e bordi di base fin dalla primissima epoca, concentrando lo sforzo computazionale esclusivamente sull'identificazione di volti e targhe.

La risoluzione delle immagini in ingresso è stata standardizzata tramite l'impostazione `imgsz = 640`. Questo valore rappresenta lo standard architetturale di base per i modelli YOLO e garantisce un bilanciamento ottimale: è una griglia sufficientemente grande per non distruggere le preziose informazioni spaziali dei target microscopici ("Small Object Detection"), ma abbastanza contenuta da non causare colli di bottiglia nella memoria video.
A tal proposito, la dimensione del lotto di addestramento è stata impostata a `batch = 16`. Questo valore permette di riempire quasi totalmente la VRAM da 15 GB delle GPU Tesla T4, garantendo un calcolo della stima del gradiente molto più stabile e meno rumoroso rispetto a lotti di dimensioni inferiori. Infine, per evitare che la GPU rimanesse in attesa dei dati dal disco fisso, il caricamento è stato parallelizzato assegnando `workers = 4`. Con questa configurazione hardware e software ottimizzata, l'intero processo di fine-tuning si è concluso con successo in 1 ora e 45 minuti.

Analisi

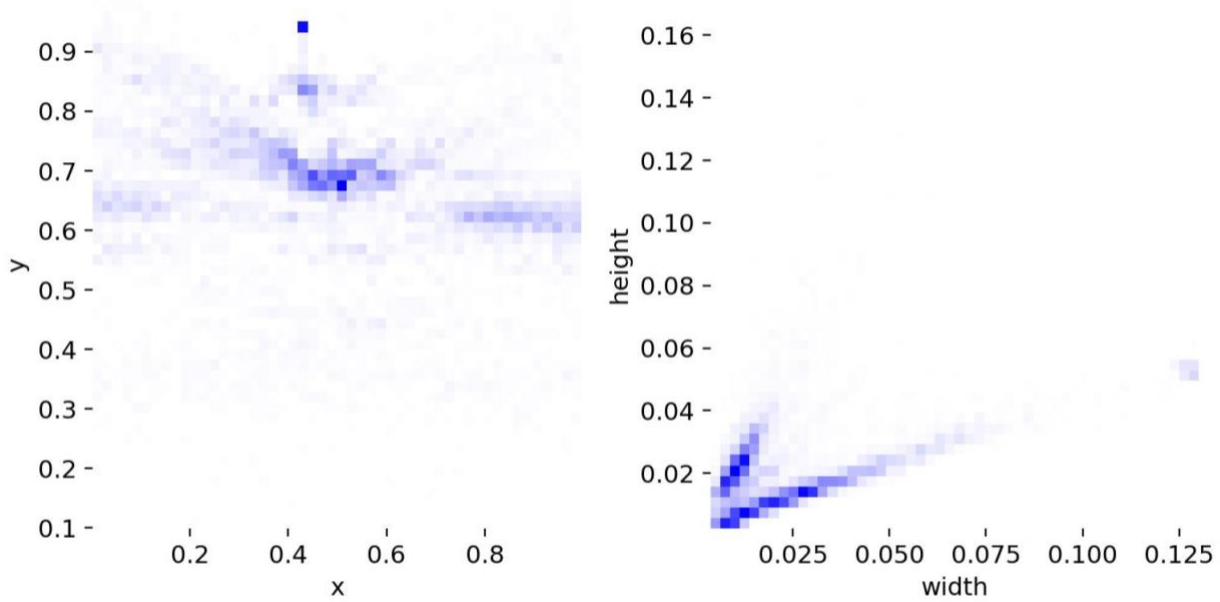

Figura 1: labels

L'analisi geometrica avanzata tramite gli **istogrammi bidimensionali** di YOLO evidenzia due aspetti fondamentali. Dal punto di vista spaziale, la mappatura delle coordinate centrali "x" e "y" mostra una massiccia concentrazione di annotazioni al centro del frame e lungo la **linea dell'orizzonte** (tra y = 0.5 e y = 0.7), confermando il tipico **effetto dashcam** della guida autonoma in cui i bersagli convergono verso il punto di fuga prospettico.
Parallelamente, l'analisi dimensionale che incrocia larghezza ("width") e altezza ("height") certifica la natura di **Small Object Detection** estrema del progetto: la quasi totalità dei **bounding box** si ammassa vicino all'origine degli assi, occupando meno del 5% dell'area visiva complessiva (valori inferiori a 0.05). Da questo denso cluster microscopico si diramano visivamente due traiettorie distinte che delineano i due **Aspect Ratio** predominanti, separando la firma geometrica allargata della classe "Targa" da quella verticalizzata della classe "Volto".

Durante le 50 epoche di fine-tuning, il comportamento della rete è stato costantemente monitorato valutandone le predizioni sul **Validation Set**, al fine di misurare la corretta convergenza dei pesi prima dei test finali.

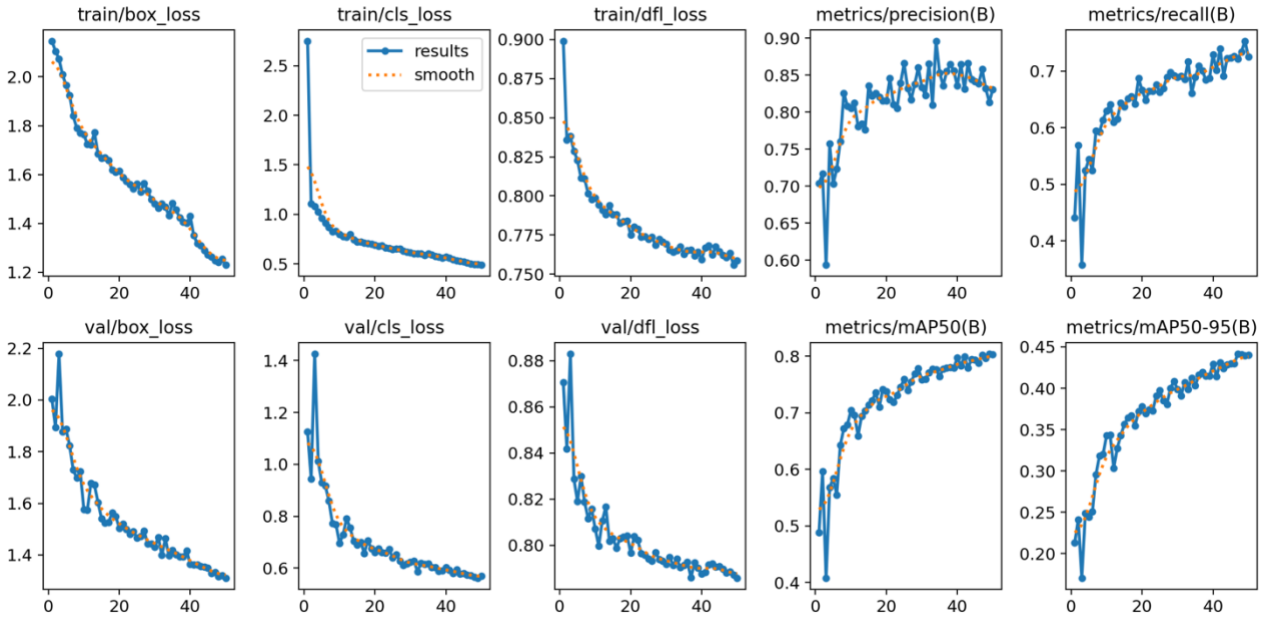

Figura 2: results

Le curve di addestramento e validazione (Figura 2: results) confermano la salute del processo di apprendimento. L'andamento decrescente delle tre componenti di perdita ("box_loss" per le coordinate, "cls_loss" per la classificazione e "dfl_loss" per i bordi) sia sul set di training che di validazione esclude la presenza di **overfitting**; la rete ha generalizzato correttamente senza imparare a memoria i dati. Parallelamente, le metriche di **Precision**, **Recall** e **mAP** mostrano una crescita asintotica regolare e stabile.

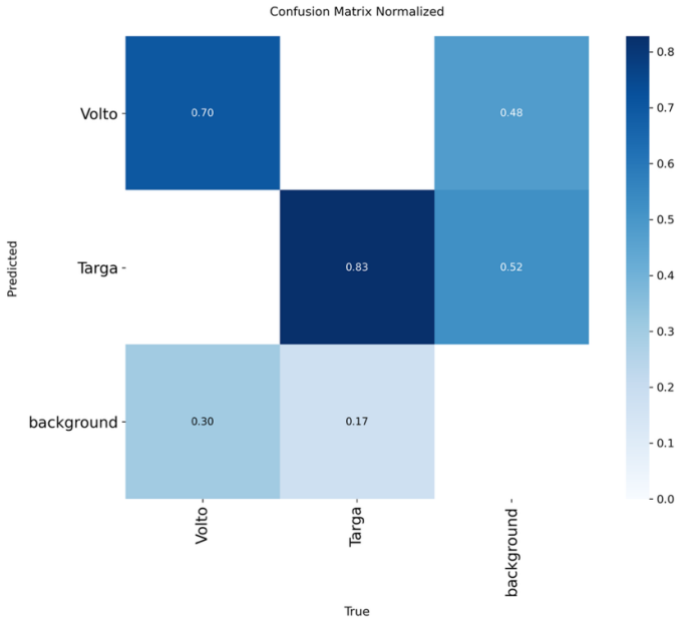

Figura 3: confusion_matrix_normalized

Analizzando la **matrice di confusione normalizzata** estratta a fine addestramento (Figura 3: confusion_matrix_normalized), emerge un'accuratezza In-Distribution dell'83% per la classe

"Targa" e del 70% per la classe "Volto". Il tasso di **falsi negativi**, ovvero gli oggetti non rilevati e confusi matematicamente con lo sfondo ("background"), si attesta al 17% per le targhe e al 30% per i volti. Questo scarto di difficoltà è fisiologico ed è pienamente giustificato dalle variazioni di posa, dall'illuminazione e dalle dimensioni microscopiche dei volti negli scenari urbani analizzati.

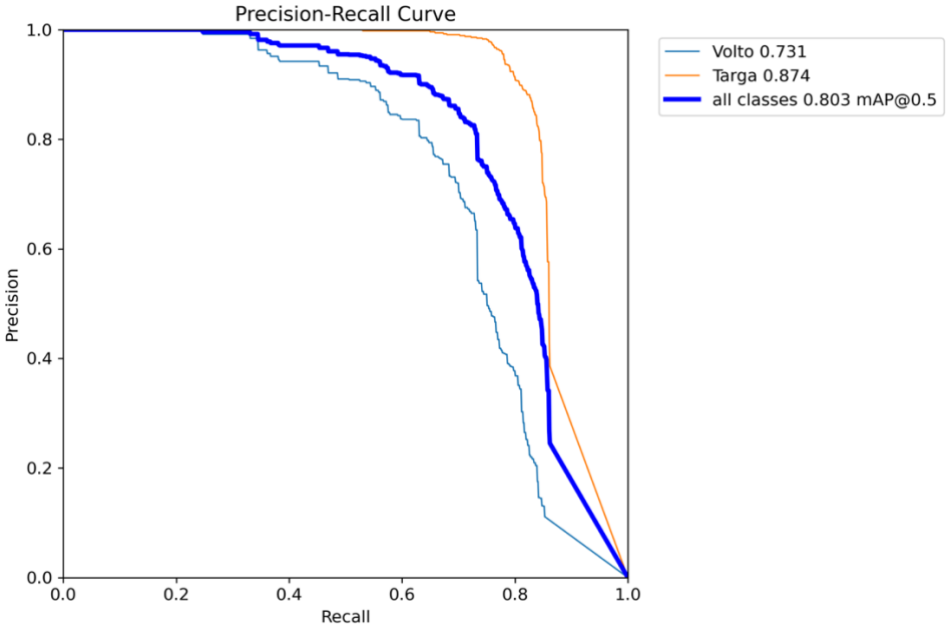

Figura 4: BoxPR_curve

Le curve di performance globali confermano tale dislivello. La **curva Precision-Recall** (Figura 4: BoxPR_curve) registra un **mAP_0.5** globale dello 0.803, con una netta superiorità della classe "Targa" (0.874) rispetto alla classe "Volto" (0.731).

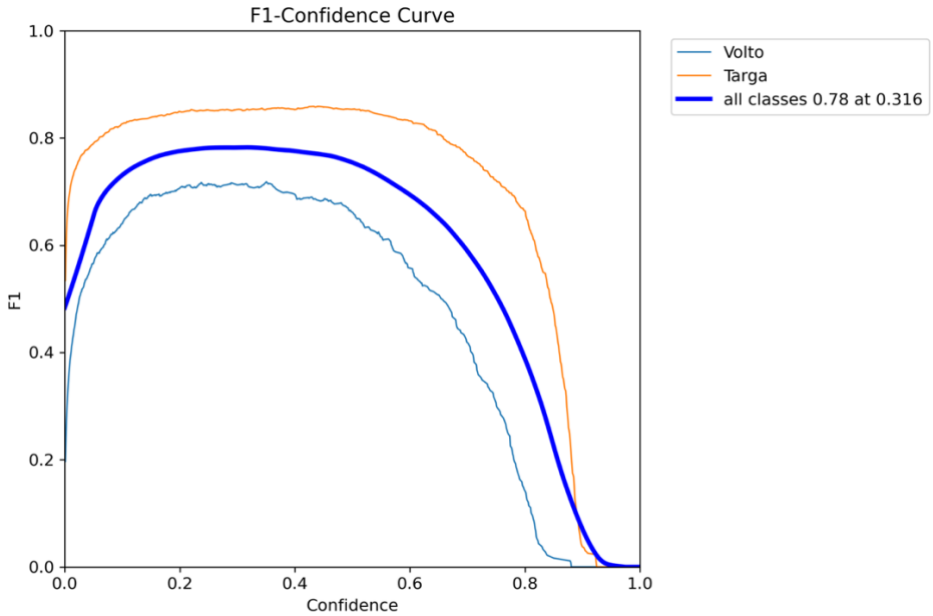

Figura 5: BoxF1_curve

Risulta inoltre di particolare interesse ingegneristico la **curva F1-Confidence** (Figura 5: BoxF1_curve), la quale individua il punto di massimo equilibrio tra falsi positivi e falsi negativi. Il grafico dimostra che la rete raggiunge il suo picco prestazionale combinato (F1 pari a 0.78) impostando la soglia di confidenza a `conf = 0.316`. Questo è il valore che verrebbe applicato in uno scenario di produzione reale per bilanciare sicurezza ed efficienza.

Figura 6: val_batch0_pred

Infine, le ispezioni visive condotte sui batch di validazione (Figura 6: val_batch0_pred) confermano qualitativamente l'eccellente capacità del modello. Come si evince dalle predizioni sovrapposte ai frame originali, la rete YOLOv9 è in grado di individuare correttamente targhe e volti anche in condizioni di parziale occlusione o notevole lontananza, mantenendo livelli di confidenza estremamente elevati (spesso tra 0.8 e 0.9) per i veicoli e i pedoni in primo piano.

Fase 3: Inferenza e Valutazione delle metriche

Conclusa la fase di addestramento, il modello ha generato automaticamente un **file** contenente i **pesi architetturali ottimali**, denominato "**best.pt**", corrispondente all'epoca in cui la loss di validazione ha toccato il suo minimo storico.

Questo file è stato **caricato in memoria** per eseguire la **fase di inferenza** (Testing) misurando le performance in modo nettamente separato sui due domini visivi. Per garantire la massima oggettività dei risultati, le valutazioni sono state eseguite forzando il calcolo su `device = 0` e disabilitando volontariamente ogni tecnica di "Test-Time Augmentation". Questo ha permesso di misurare le capacità predittive grezze della rete, senza "aiuti" algoritmici.

	Normal images		Fisheye images	
Classe	**AP_0.5**	**AR_0.5**	**AP_0.5**	**AR_0.5**
Face	81.12%	72.39%	23.72%	23.99%
Plate	86.91%	79.18%	43.90%	35.27%

I **risultati** registrati sul **Test Set "Normal"** (In-Distribution) confermano la validità del setup di addestramento e l'eccellente capacità estrattiva del modello.

Sulla **classe "Targa"**, il modello ha registrato un punteggio **AP_0.5 del 86.91%** e una **AR_0.5 del 79.18%**.

Sulla **classe "Volto"**, anch'essa caratterizzata da dimensioni relative minime, ha raggiunto un **AP_0.5 del 81.12%** e un **AR_0.5 del 72.39%**.

A livello globale, le metriche medie combinate mostrano una **Precision del 88.22%** e un solido **mAP_0.5 del 84.01%**.

Questi valori dimostrano che YOLOv9 è perfettamente in grado di individuare oggetti molto piccoli in uno scenario urbano complesso, purché la prospettiva sia lineare.

Tuttavia, l'analisi condotta sul **Test Set "Fisheye"** (Out-of-Distribution) ha restituito il dato scientificamente più critico e rilevante dell'intera sperimentazione, palesando un **crollo verticale delle prestazioni** di rilevamento.

Sulla **classe "Targa"**, la metrica **AP_0.5 precipita al 43.90%** e l'**AR_0.5 si ferma ad appena il 35.27%**.

Ancora più drastico risulta il calo sulla **classe "Volto"**, dove l'**AP_0.5 scende al 23.72%** e l'**AR_0.5 al 23.99%**.

La **motivazione** alla base di questo collasso prestazionale risiede in un fenomeno definibile come "Overfitting Geometrico" . I **filtri convoluzionali** della rete neurale profonda, durante le 50 epoche di studio, si sono **iper-specializzati** nell'estrarre feature legate a **forme** strettamente **rettangolari** e **proporzioni fisse** situate su piani prospettici convenzionali. Non essendo mai stati esposti alla distorsione radiale tipica delle lenti a 360 gradi durante il calcolo della loss, questi **filtri non** sono matematicamente **strutturati** per **riconoscere un rettangolo** quando questo viene **curvato**, **stirato** ed **espanso ai bordi** dell'inquadratura sferica.

Il drastico calo delle metriche registrato nel dominio "Fisheye" trova una inequivocabile spiegazione tecnica e ingegneristica analizzando gli output grafici della rete neurale. Il primo strumento diagnostico è la **matrice di confusione normalizzata** estratta durante il test Out-of-Distribution.

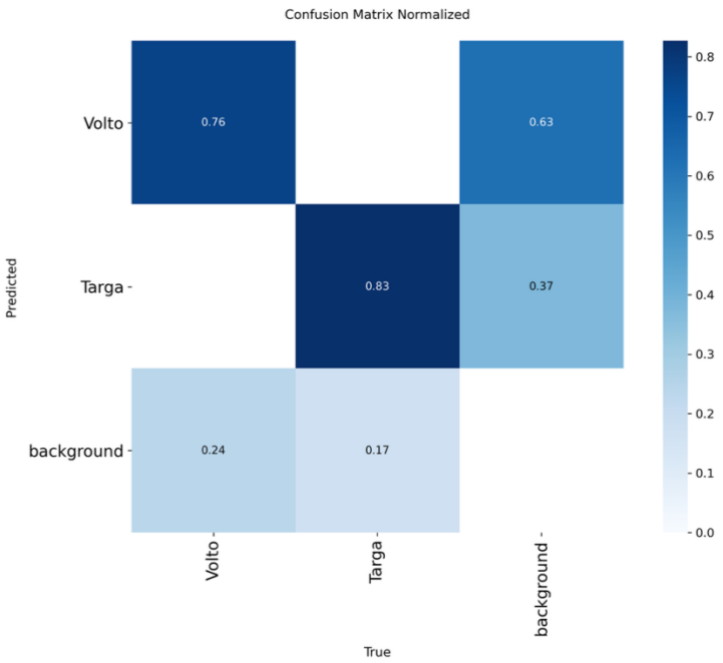

Figura 7: confusion_matrix_normalized_normal

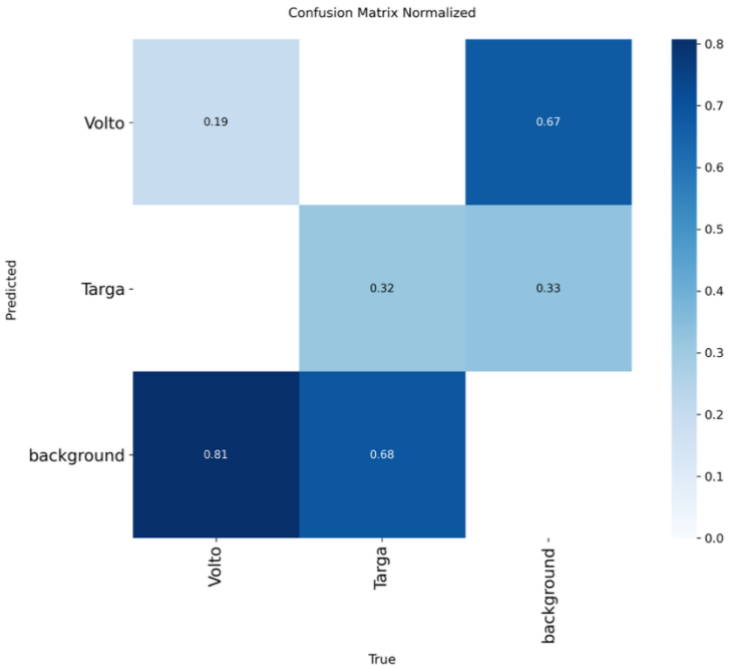

Figura 8: confusion_matrix_normalized_fisheye

A differenza dello scenario standard (Figura 7: confusion_matrix_normalized_normal), dove la maggior parte delle **istanze** si allinea **correttamente sulla diagonale principale**, la matrice del dominio distorto (Figura 8: confusion_matrix_normalized_fisheye) mostra una **migrazione massiccia** delle probabilità verso la classe "background" (sfondo).

Questo comportamento certifica che il modello non sta semplicemente confondendo le due classi tra loro, ma sta letteralmente subendo una "cecità visiva". I filtri convoluzionali, non essendo addestrati a riconoscere geometrie curve, considerano i pixel delle targhe deformate come semplice

rumore di strada, generando una quantità critica di **falsi negativi** (l'81% per i volti e il 68% per le targhe).

Figura 9: val_batch0_lables_fisheye

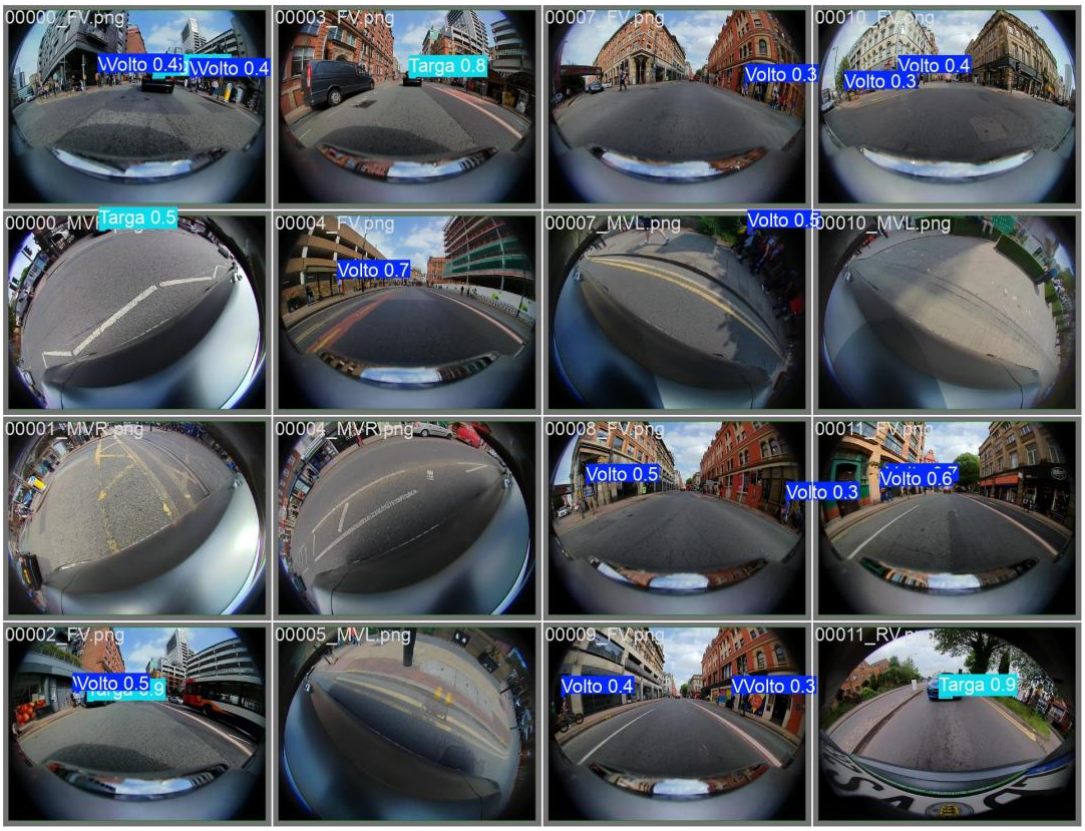

Figura 10: val_batc0_pred_fisheye

Il crollo delle metriche registrato nel dominio "Fisheye" trova una spiegazione tecnica inequivocabile analizzando gli output grafici della rete neurale. Per questa diagnosi, è stato eseguito un confronto diretto tra le **label** (le annotazioni reali della verità sul campo, Figura 9: val_batch0_labels_fisheye) e le **predizioni** effettive del modello (Figura 10: val_batch0_pred_fisheye) per lo stesso batch di validazione.

Questo confronto affiancato chiarisce il meccanismo d'errore. Le **label** originali mostrano la presenza di numerosi volti e targhe annotati con precisione, anche nelle aree periferiche del frame che subiscono la massima deformazione radiale della lente sferica. Al contrario, l'immagine delle predizioni del modello mostra una situazione di totale cecità visiva. La rete YOLOv9 non riesce ad ancorare quasi nessun **bounding box** corretto.

Osservando le predizioni, emerge un pattern di errore sistematico: la rete riesce a individuare con buona confidenza (spesso `conf = 0.80`) i rari target situati nel centro esatto dell'inquadratura, zona in cui la distorsione è geometricamente minima e approssimabile a una prospettiva lineare. Tuttavia, non appena i veicoli o i pedoni si spostano verso la periferia subendo il severo stiramento radiale, il modello smette di riconoscere le feature geometriche delle classi. Di conseguenza, i pixel corrispondenti vengono interpretati come semplice rumore di strada, generando una quantità critica di **falsi negativi**.

Questo **esperimento dimostra** in modo inequivocabile che la pura potenza architetturale di YOLOv9, per quanto avanzata, non è sufficiente a garantire la comprensione "Zero-Shot" di una deformazione ottica. Tale conclusione tecnica giustifica pienamente il problema di ricerca sollevato e rende indispensabile l'avvio del Secondo Ciclo Sperimentale per investigare l'Adattamento al Dominio.

5.2 Secondo ciclo sperimentale

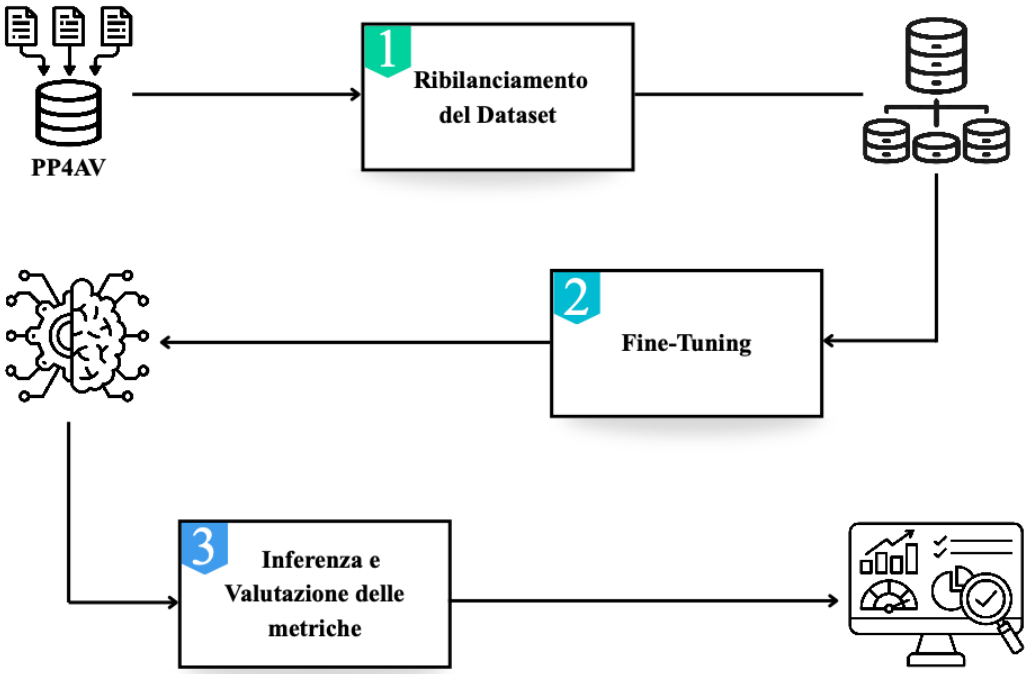

Fase 1: Ribilanciamento del Dataset

L'obiettivo primario di questa seconda fase sperimentale è la **risoluzione del problema** dell'**Overfitting Geometrico** emerso nel ciclo precedente. Per permettere alla rete neurale di apprendere e compensare attivamente la distorsione radiale, si è reso necessario un riposizionamento strategico dei dati, passando da una valutazione "Zero-Shot" a una vera e propria architettura di **Mixed-Domain Training**. Questo approccio garantisce inoltre un confronto metodologico equo con la baseline del paper ufficiale, che addestrava l'architettura YOLOX esponendola fin dall'inizio alle deformazioni ottiche.

A differenza del primo split fortemente asimmetrico, in questa fase è stata applicata una **regola di partizionamento omogenea** a tutte le cartelle geografiche del dataset PP4AV, includendo esplicitamente il dominio "Fisheye". Ho applicato un rigoroso taglio dell'80-10-10 su ogni scenario operativo. I set di addestramento e validazione sono stati progettati per fondere dinamicamente le immagini lineari e quelle grandangolari. Al contrario, per preservare la capacità di valutare le prestazioni finali in modo isolato e oggettivo, la porzione del 10% dedicata al test finale è stata instradata selettivamente in due directory separate.

La nuova esecuzione dello script ha prodotto la seguente allocazione strutturale:

- **Training Set (80%)**: cartella mista che aggrega l'80% delle immagini urbane standard e l'80% delle immagini Fisheye. Questa fusione forza i filtri convoluzionali ad adattarsi nativamente a geometrie variabili durante il ricalcolo del gradiente.
- **Validation Set (10%)**: cartella di monitoraggio mista (10% normali e 10% fisheye), essenziale per misurare la convergenza della "loss" su entrambi i domini in simultanea.
- **Test Set "Normal" (10%)**: cartella dedicata esclusivamente al test finale sulle immagini a prospettiva lineare, rigorosamente non osservate durante l'addestramento.
- **Test Set "Fisheye" (10%)**: cartella isolata contenente l'ultimo decile delle immagini con lenti a 360 gradi, indispensabile per quantificare il successo dell'adattamento al dominio distorto.

Fase 2: Fine-Tuning

L'ambiente di addestramento è stato implementato sfruttando l'infrastruttura **cloud Kaggle**, che ha permesso l'allocazione hardware su acceleratori **GPU NVIDIA Tesla T4** in configurazione doppia. Il modello selezionato per l'esperimento rimane YOLOv9 nella sua variante compatta, identificata dal file "`yolov9c.pt`". Aver mantenuto la medesima architettura del primo ciclo è un requisito fondamentale per il rigore metodologico dello **studio di ablazione** ("Ablation Study"): garantisce che qualsiasi variazione nelle metriche finali sia imputabile esclusivamente alla nuova distribuzione dei dati e non a un potenziamento intrinseco della rete neurale.

Gli iperparametri di addestramento sono stati selezionati per bilanciare l'efficienza hardware con la nuova e più elevata complessità del task. A differenza del ciclo precedente, infatti, i filtri convoluzionali devono ora minimizzare la funzione di perdita ("loss") imparando a estrarre le **feature** di volti e targhe contemporaneamente in prospettiva lineare e sotto la severa **distorsione radiale** delle lenti a 360 gradi.

Il parametro di durata è stato mantenuto a `epochs = 50` come orizzonte temporale esplorativo. Per accelerare la convergenza iniziale e sfruttare l'estrazione di forme e bordi di base, è stato confermato l'utilizzo del **Transfer Learning** tramite l'abilitazione di `pretrained = True`, caricando i pesi già ottimizzati sul massivo dataset generico COCO.

La risoluzione delle immagini in ingresso è stata standardizzata tramite l'impostazione `imgsz = 640`. Questo valore garantisce il corretto funzionamento del modulo **Programmable Gradient Information** di YOLOv9 nella conservazione dei dettagli spaziali, un fattore critico dato l'elevato numero di target microscopici ("Small Object Detection"). La dimensione del lotto di addestramento è stata fissata a `batch = 16`, saturando la VRAM disponibile per stabilizzare la

discesa del gradiente durante la complessa fusione dei due domini visivi. Infine, il caricamento in memoria dal disco è stato parallelizzato assegnando `workers = 4`. Con questa configurazione hardware e software ottimizzata per il dominio misto, l'intero processo di fine-tuning si è concluso con successo in 1 ora e 47 minuti.

Analisi

Durante le 50 epoche di fine-tuning, il comportamento della rete in questo nuovo dominio misto è stato costantemente monitorato valutandone le predizioni sul **Validation Set** ibrido, al fine di misurare la corretta convergenza dei pesi prima dei test finali.

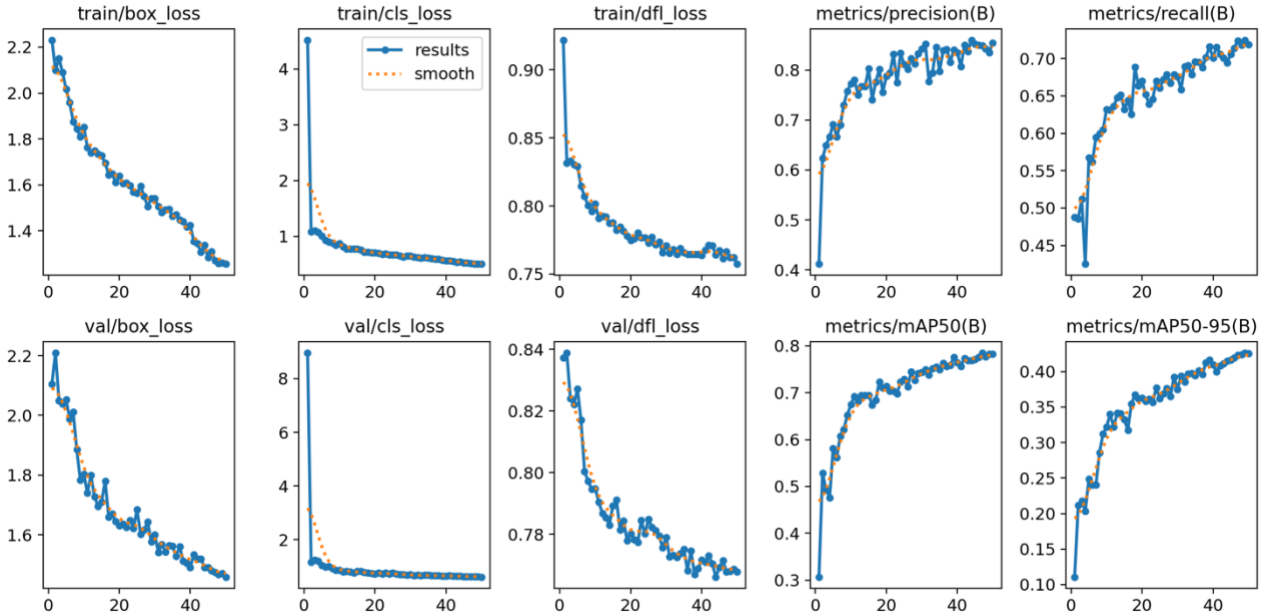

Figura 11: results

Le curve di addestramento e validazione (Figura 11: results.jpg) confermano la salute del processo di apprendimento in scenario "Mixed-Domain". L'andamento decrescente delle tre componenti di perdita ("box_loss" per le coordinate, "cls_loss" per la classificazione e "dfl_loss" per i bordi) sia sul set di training che di validazione esclude la presenza di **overfitting** prematuro. L'introduzione della severa aberrazione radiale non ha destabilizzato la rete, la quale ha generalizzato correttamente le nuove geometrie senza imparare a memoria i dati. Parallelamente, le metriche di **Precision**, **Recall** e **mAP** mostrano una crescita asintotica regolare.

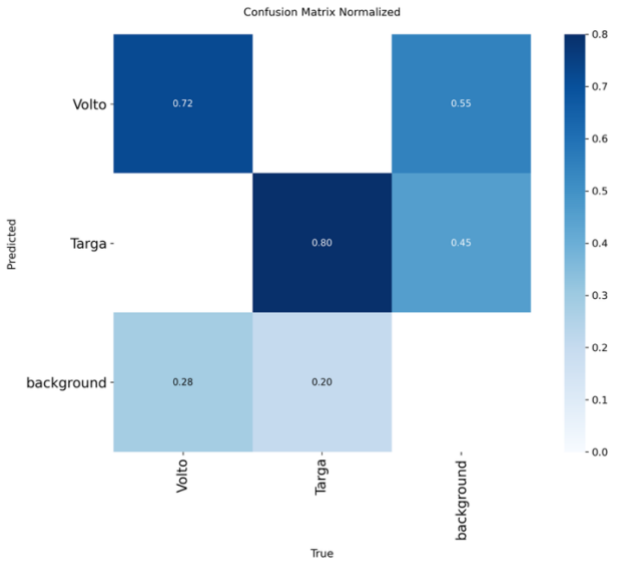

Figura 12: confusion_matrix_normalized

Analizzando la **matrice di confusione normalizzata** estratta a fine addestramento (Figura12: confusion_matrix_normalized), emerge un'accuratezza globale dell'80% per la classe "Targa" e del 72% per la classe "Volto". Rispetto allo scenario "Zero-Shot" del primo ciclo, si nota un adattamento al dominio: il tasso di **falsi negativi** (oggetti non rilevati e confusi con il "background") si attesta al 20% per le targhe (con un lieve e fisiologico peggioramento dovuto alla distorsione) e al 28% per i volti (in netto miglioramento). La rete ha bilanciato i suoi sforzi, sacrificando una minima percentuale di confidenza sulle targhe standard per acquisire la capacità di individuare più volti, dimostrando l'efficacia del nuovo split.

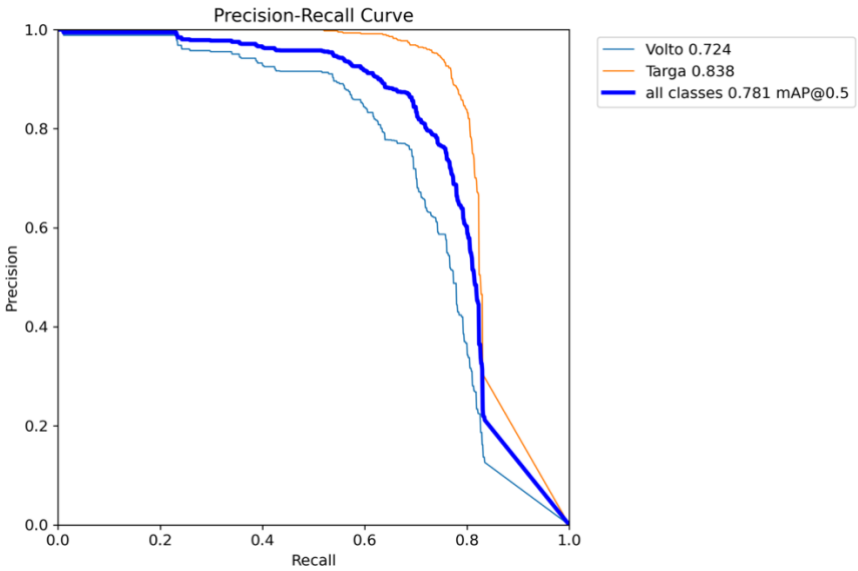

Figura 13: BoxPR_curve

Le curve di performance globali riflettono questa nuova complessità geometrica. La **curva Precision-Recall** (Figura 13: BoxPR_curve) registra un **mAP_0.5** globale dello 0.781,

mantenendo una netta superiorità della classe "Targa" (0.838) rispetto alla classe "Volto" (0.724). Sebbene il mAP globale sia lievemente inferiore rispetto all'addestramento In-Distribution puro del primo ciclo, l'area sotto la curva si mantiene su livelli accademici di eccellenza, confermando che l'architettura YOLOv9 possiede una capacità estrattiva sufficiente per gestire due domini ottici simultaneamente.

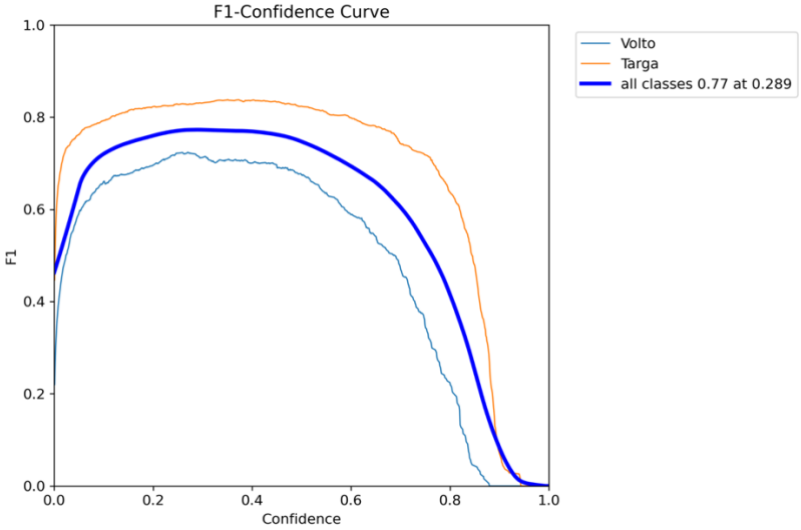

Figura 14: BoxF1_curve

Risulta inoltre di particolare interesse ingegneristico la **curva F1-Confidence** (Figura 14: BoxF1_curve), la quale individua il punto di massimo equilibrio tra falsi positivi e falsi negativi in questo nuovo scenario sfidante. Il grafico dimostra che la rete raggiunge il suo picco prestazionale combinato (F1 pari a 0.77) impostando la soglia di confidenza a conf = 0.289. Questo abbassamento della soglia ottimale rispetto al primo ciclo è un indicatore cruciale: la rete ha imparato a essere più "permissiva" pur di riuscire a catturare le forme pesantemente deformate dal Fisheye.

Figura 15: val_batch0_pred

Infine, le ispezioni visive condotte sui batch di validazione dominanti (Figura 15: val_batch0_pred) confermano qualitativamente la solidità della base di conoscenza del modello. Come si evince dalle predizioni sovrapposte ai frame originali, la rete continua a individuare correttamente targhe e volti mantenendo livelli di confidenza estremamente elevati nelle prospettive lineari. Questa è la prova visiva che il **Mixed-Domain Training** non ha causato "catastrophic forgetting" (dimenticanza catastrofica): la rete ha appreso il nuovo dominio distorto senza distruggere la sua eccellente capacità di operare in scenari urbani standard.

Fase 3: Inferenza e Valutazione delle metriche

Conclusa la seconda **fase di addestramento** in regime di "Mixed-Domain", il modello ha generato automaticamente un **nuovo file** contenente i pesi architetturali ottimali, denominato "**best.pt**", corrispondente all'epoca in cui la loss di validazione ha toccato il suo minimo storico considerando entrambi i domini visivi.

Questo file è stato **caricato** in memoria per **eseguire la fase di inferenza** (Testing), misurando le performance in modo nettamente separato sui due set.

	Normal images		Fisheye images	
Classe	**AP_0.5**	**AR_0.5**	**AP_0.5**	**AR_0.5**
Face	77.65%	74.29%	43.68%	38.46%
Plate	91.16%	86.86%	83.31%	81.82%

I **risultati** registrati sul **Test Set** "**Normal**" (In-Distribution) **confermano la solidità** del nuovo setup di addestramento misto.
Sulla **classe "Targa"**, il modello ha registrato un punteggio **AP_0.5** eccezionale del **91.16%** e una **AR_0.5** del **86.86%**.
Sulla **classe "Volto"**, ha raggiunto un **AP_0.5** del **77.65%** e un **AR_0.5** del **74.29%**.
A livello globale, le metriche medie combinate mostrano una **Precision** del **83.43%** e un solido **mAP_0.5** del **84.41%**.
Questi valori dimostrano che l'**architettura YOLOv9**, anche se **sottoposta a** uno **stress geometrico** durante il training, **mantiene** intatta la sua **eccellente capacità** di individuare oggetti molto piccoli in uno scenario a prospettiva lineare.

L'**analisi** condotta sul **Test Set** "**Fisheye**" (Target Domain) ha restituito il dato scientificamente più esaltante e rilevante della sperimentazione, palesando un **recupero** formidabile delle **prestazioni** di rilevamento e la definitiva guarigione del modello.
Sulla **classe "Targa"**, la metrica **AP_0.5** sale vertiginosamente all'**83.31%** e l'**AR_0.5** raggiunge un notevole **81.82%**.
Anche sulla **classe "Volto"**, intrinsecamente più complessa a causa della perdita di risoluzione ai bordi della lente, l'**AP_0.5** sale al **43.68%** e l'**AR_0.5** al **38.46%**.

La **motivazione** alla base di questo **successo** prestazionale risiede nell'efficacia del "**Mixed-Domain Training**". I filtri convoluzionali della rete neurale profonda, durante l'addestramento ibrido, sono stati costretti a estrarre feature da immagini standard e deformate contemporaneamente. Essendo stati esposti regolarmente alla distorsione radiale tipica delle lenti a 360 gradi durante il ricalcolo della loss, i filtri si sono adattati dinamicamente.
Ora la rete è strutturata per riconoscere le proporzioni di un veicolo o di un pedone anche quando queste geometrie vengono curvate, stirate ed espanse ai bordi dell'inquadratura sferica, superando con successo il fenomeno dell'Overfitting Geometrico diagnosticato nel ciclo precedente.

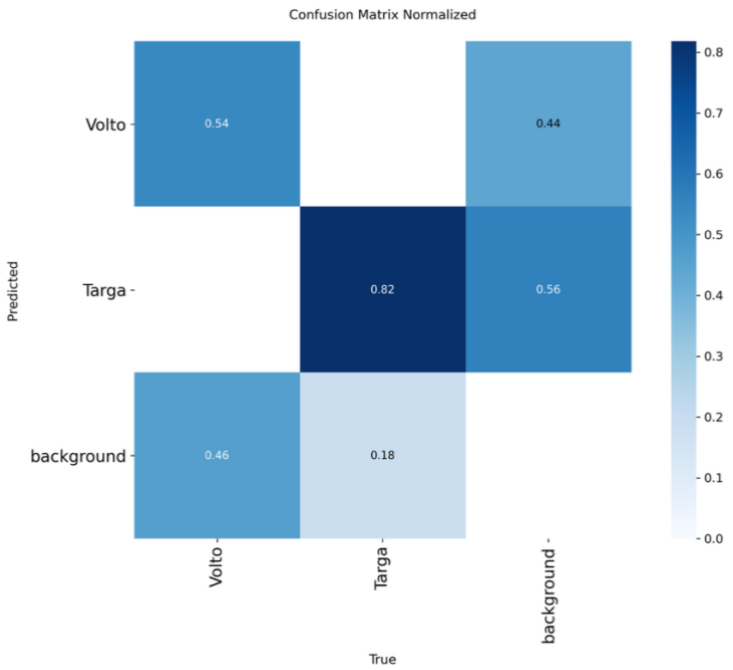

Figura 16: confusion_matrix_normalized_fisheye

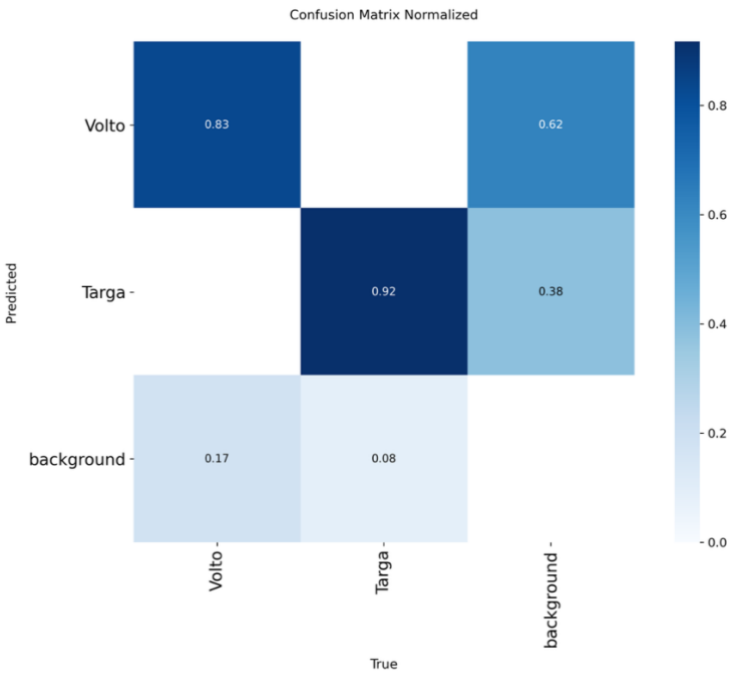

Figura 17: confusion_matrix_normalized_normal

A differenza del primo ciclo sperimentale, in cui la matrice del dominio distorto mostrava un collasso sistematico, l'attuale matrice "Fisheye" (Figura 16: confusion_matrix_normalized_fisheye) dimostra che la migrazione massiccia delle probabilità verso la classe "background" (sfondo) è stata bloccata. I filtri convoluzionali, grazie al **Mixed-Domain Training**, hanno imparato a riconoscere le geometrie curve.

Di conseguenza, la quantità critica di **falsi negativi** si è ridotta drasticamente, crollando dal 68% al 18% per la classe "Targa" e dall'81% al 46% per la classe "Volto".

Parallelamente, lo scenario standard (Figura 17: confusion_matrix_normalized_normal) mantiene la sua solidità strutturale, con il 92% delle targhe classificate correttamente, escludendo il rischio di dimenticanza catastrofica.

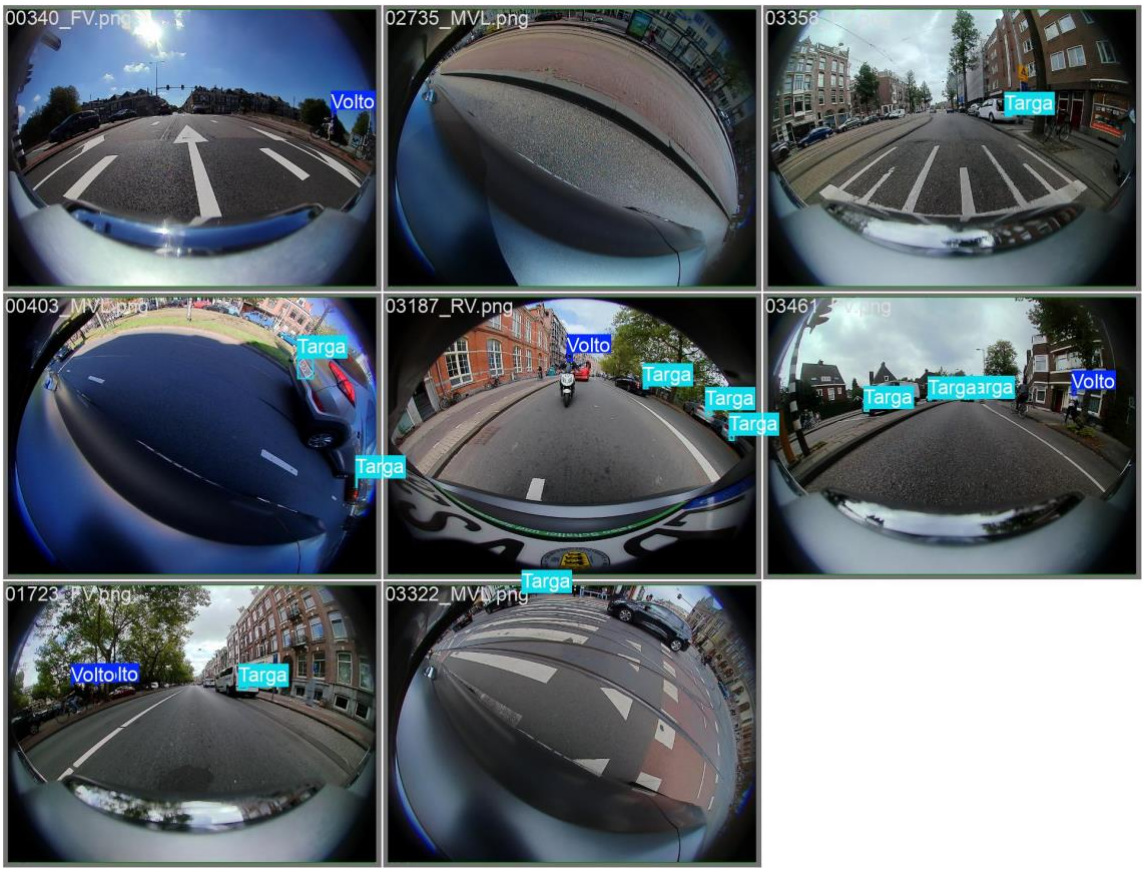

Figura 18: val_batch2_lables_fisheye

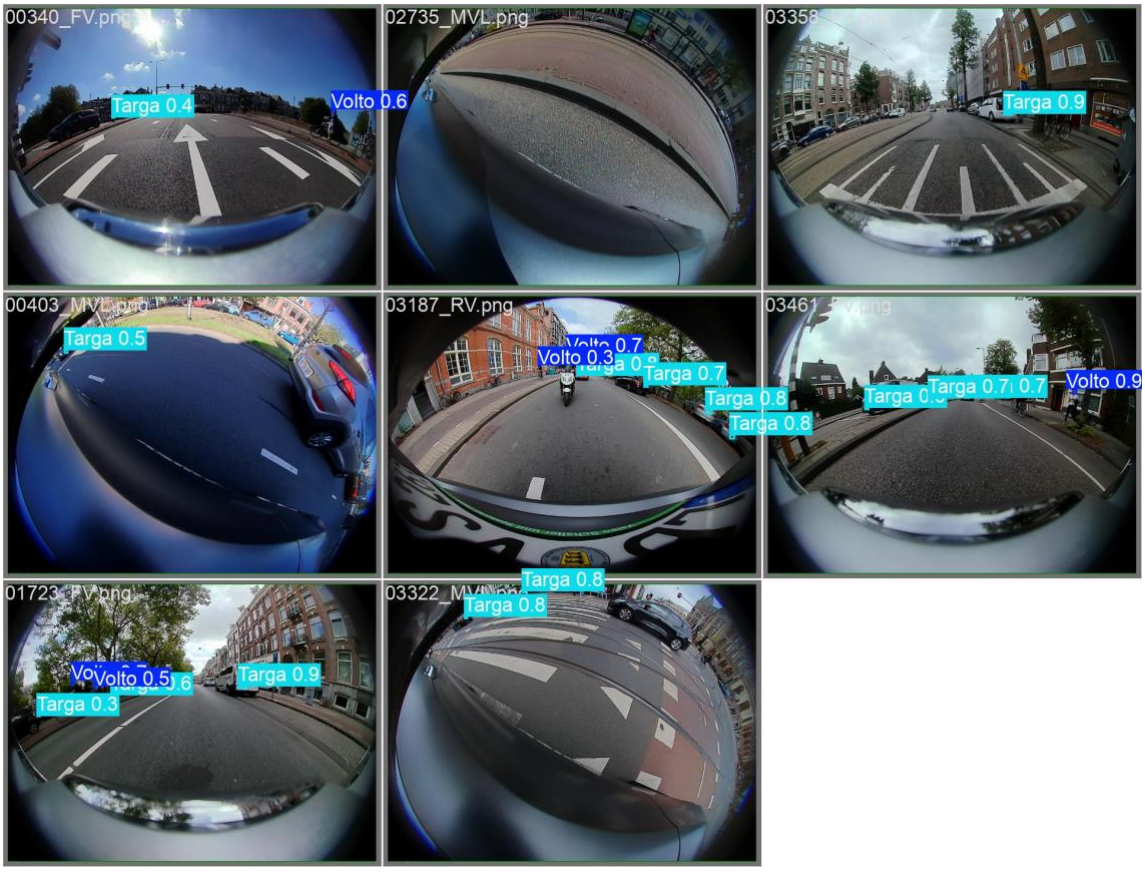

Figura 19: val_batch2_pred_fisheye

Il superamento dell'**Overfitting Geometrico** trova una spiegazione visiva definitiva analizzando le predizioni grafiche della rete neurale. Anche in questo caso, è stato eseguito un confronto diretto tra le **label** (le annotazioni reali, Figura 18: val_batch2_labels_fisheye) e le **predizioni** effettive del modello ottimizzato (Figura 19: val_batch2_pred_fisheye).
Questo confronto affiancato chiarisce il nuovo meccanismo di rilevamento. A differenza del ciclo "Zero-Shot", dove l'immagine mostrava una situazione di totale cecità visiva ai bordi, ora la rete YOLOv9 riesce ad ancorare i **bounding box** con straordinaria precisione sull'intera inquadratura. Osservando le predizioni, emerge la rottura del pattern di errore sistematico: il modello individua con elevata confidenza (frequentemente tra conf = 0.70 e conf = 0.90) non solo i target centrali, ma anche i veicoli e i pedoni situati nella periferia dell'immagine, nonostante il severo stiramento radiale a barile.

Questo esperimento dimostra in modo inequivocabile che la combinazione tra un addestramento ibrido mirato all'**Adattamento al Dominio** dota un'architettura State-of-the-Art come YOLOv9 della flessibilità necessaria per operare in contesti ottici non convenzionali.

6. Confronto: Baseline, Ciclo sperimentale 1 e Ciclo sperimentale 2

Dominio e Classe	Metrica	Baseline (YOLOX)	Ciclo 1 ("Zero-Shot")	Ciclo 2 ("Mixed-Domain")	Variazione
Normal - "Targa"	AP_0.5	88.12%	86.91%	**91.16%**	**+3.04%**
	AR_0.5	**91.88%**	79.18%	86.86%	**-5.02%**
Normal - "Volto"	AP_0.5	76.22%	81.12%	**77.65%**	**+1.43%**
	AR_0.5	**92.52%**	72.39%	84.29%	**-8.23%**
Fisheye - "Targa"	AP_0.5	49.53%	43.90%	**83.31%**	**+33.78%**
	AR_0.5	58.17%	35.27%	**81.82%**	**+23.65%**
Fisheye - "Volto"	AP_0.5	**59.20%**	23.72%	43.68%	**-15.52%**
	AR_0.5	**63.92%**	23.99%	38.46%	**-25.46%**

Sulla **classe "Targa"**, ovvero la classe geometricamente dominante, il **modello** elaborato nel **Ciclo 2 disintegra le prestazioni della Baseline**. Sul dominio **"Normal"**, YOLOv9 stabilisce un nuovo primato superando la soglia del **91%** di AP (+3.04%), accettando un fisiologico e marginale calo di Recall (-5.02%) a favore di una maggiore precisione (riduzione dei falsi positivi).
Ma è sul dominio **"Fisheye"** che si registra il vero capolavoro ingegneristico: l'**AP_0.5** balza dal 49.53% di YOLOX a un eccezionale **83.31%**, segnando un miglioramento assoluto di +33.78%. Parallelamente, l'incremento dell'**AR_0.5** all'**81.82%** (+23.65% rispetto alla Baseline) certifica che la rete non solo è più precisa, ma individua un numero significativamente maggiore di targhe distorte, riducendo drasticamente i falsi negativi. L'architettura ottimizzata ha imparato a decodificare le deformazioni geometriche in modo infinitamente superiore al modello originale.

Di contro, si osserva un calo del **-15.52%** in termini di AP e del **-25.46%** in termini di AR sulla **classe "Volto"** nel dominio **"Fisheye"** rispetto alla Baseline. Durante il fine-tuning del Ciclo 2, i filtri convoluzionali di YOLOv9 hanno massimizzato l'ottimizzazione della funzione di perdita (*loss*) concentrandosi sulla classe "Targa", a discapito dei micro-pixel che compongono i volti sgranati ai bordi della lente sferica.

1. La Baseline Originale (YOLOX)

- **Punti di forza:** il modello YOLOX proposto nel paper originale affronta il problema esponendo nativamente la rete all'intero set di dati misto (lineare e grandangolare). Questa scelta garantisce una certa stabilità di base, evitando crolli improvvisi delle prestazioni al cambio di lente.
- **Punti di debolezza:** essendo un'architettura di generazione precedente (anchor-free ma priva dei moderni moduli di conservazione del gradiente), YOLOX mostra limiti intrinseci nel task estremo di **Small Object Detection**, faticando a estrarre feature sufficienti per i bersagli più microscopici e lontani, specialmente in condizioni estreme.

2. Primo Ciclo Sperimentale (YOLOv9 "Zero-Shot")

- **Punti di forza:** l'introduzione di YOLOv9 ha dimostrato una superiorità estrattiva schiacciante negli scenari a prospettiva lineare. Sfruttando il modulo **Programmable Gradient Information**, il modello ha raggiunto metriche di eccellenza nel dominio "Normal". Si è dimostrato il miglior estrattore puro per contesti urbani standard ("In-Distribution").
- **Punti di debolezza:** l'isolamento forzato dal dominio distorto durante l'addestramento ha scatenato il fenomeno dell'**Overfitting Geometrico**. Il modello ha fallito il test "Zero-Shot" sul set "Fisheye", evidenziando una drammatica "cecità visiva" ai bordi della lente. La debolezza principale risiede nell'incapacità di generalizzare deformazioni spaziali mai osservate durante l'aggiornamento dei pesi.

3. Secondo Ciclo Sperimentale (YOLOv9 "Mixed-Domain")

- **Punti di forza:** tramite il **Mixed-Domain Training**, il modello ha curato l'overfitting geometrico senza subire dimenticanza catastrofica sui dati normali, permettendo alla rete di compensare la perdita di risoluzione della lente sferica, facendo balzare l'AP_0.5 della classe "Targa" sullo scenario "Fisheye" a un eccezionale 83.31%.
- **Punti di debolezza:** il recupero formidabile delle metriche porta con sé un inevitabile aumento del **costo computazionale**.

7. Sperimentazione 2: Approccio Data-Centric

Il secondo flusso di lavoro rappresenta il nucleo del Ciclo sperimentale 3. A differenza del precedente approccio focalizzato esclusivamente sul modello (Model-Centric), questa fase sposta l'**attenzione sulla manipolazione** e **sull'ottimizzazione** del set di **dati**. L'**obiettivo** primario è **risolvere le criticità** emerse durante il Ciclo 2, in particolare il drastico calo di prestazioni della classe "Volto" nel dominio ottico deformato. Il flusso si articola in tre fasi sequenziali, come illustrato nello schema:

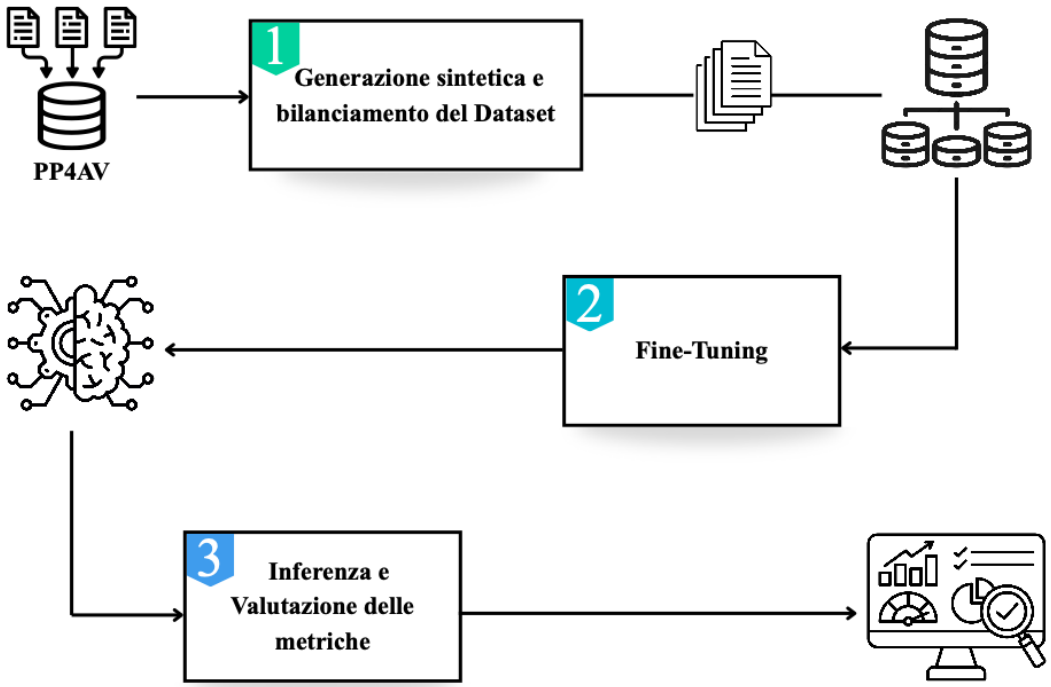

Fase 1: Generazione sintetica e bilanciamento del Dataset

Questa fase costituisce il **cuore** dell'**approccio** "**Data-Centric**" e mira a risolvere alla radice lo squilibrio di dominio del dataset PP4AV originale. Il processo non si limita a un semplice campionamento, ma richiede una rigorosa *pipeline* che ho strutturato nei seguenti passaggi:

Analisi del divario e campionamento mirato

Inizialmente viene effettuata un'analisi sul set di addestramento ottenuto dallo split2 (`images/train`), operando una **classificazione automatica** basata sulla **nomenclatura** dei file:

- le immagini standard presentano un prefisso alfabetico (**normal**);
- le immagini reali acquisite con lenti grandangolari possiedono una formattazione numerica (**fisheye**).

Sulla base di questo conteggio, il sistema calcola matematicamente il *gap* numerico esatto (**num_da_generare**). Successivamente viene estratto casualmente un campione di immagini lineari di volume esattamente pari al *gap* calcolato. Questo assicura il raggiungimento di un rapporto finale 50/50 tra i due domini ottici.

Clipping

Prima di applicare le trasformazioni visive, è stata progettata una **fase di sicurezza** per le annotazioni in formato YOLO. Calcolando i vertici dei *bounding box* originari, l'algoritmo effettua un taglio matematico (*clipping*) forzato, assicurandosi che **nessuna coordinata superi i limiti spaziali dell'immagine**, definiti dal *range* rigoroso [0.0, 1.0]. I *box* che, a seguito di questa correzione o di annotazioni originarie errate, presentano un'area irrilevante (inferiore a "0.001"), vengono automaticamente scartati. Questo passaggio "igienizza" il dato ed evita errori bloccanti o corruzioni matematiche durante le successive fasi di manipolazione.

Il motore di distorsione (Warping Spaziale)

Le immagini ottenute vengono elaborate tramite la **libreria Albumentations**. Alla base della generazione vi è l'applicazione del modulo `OpticalDistortion` configurato con un parametro `distort_limit = 0.8`. Questa funzione **applica una deformazione radiale estrema** (distorsione a barile), stirando i pixel centrali verso l'esterno per emulare le aberrazioni geometriche indotte da lenti ultragrandangolari.

In parallelo, il modulo `BboxParams` si fa carico della complessa operazione di **adattamento delle annotazioni**. I rettangoli vengono spostati e ridimensionati per ricalcare la nuova geometria degli oggetti deformati. Un ulteriore filtro dinamico (`min_visibility = 0.2`) provvede a eliminare automaticamente le etichette di quegli oggetti (come volti o targhe) spinti troppo oltre i bordi della lente, evitando l'introduzione di "rumore" nel dataset.

Assemblaggio del "Super-Dataset" (Split 3) e architettura YAML

La fase conclusiva prevede la strutturazione fisica e logica dei nuovi dati. Per scongiurare il fenomeno del *Data Leakage* (contaminazione dei dati), viene creata una nuova gerarchia di cartelle ("dataset_split3"). I set di validazione e di test (sia *normal* che *fisheye*) vengono copiati integralmente e mantenuti invariati rispetto allo split2.

Le immagini sintetiche generate (identificabili dal prefisso "synth_albu_") vengono iniettate **esclusivamente** all'interno del *Training Set*, fondendosi con i dati originali.

Fase 2: Fine-Tuning

Una volta ottenuto il "nuovo dataset", il *workflow* procede con la fase di addestramento (**Fine-Tuning**) dell'architettura **YOLOv9**. In questo terzo ciclo sperimentale, l'obiettivo non è semplicemente far convergere il modello sui nuovi dati, ma guidare attivamente l'aggiornamento dei pesi della rete neurale per correggere le specifiche debolezze emerse nel Ciclo 2, unendo il **bilanciamento fisico dei domini** a un rigoroso **bilanciamento matematico della funzione di errore (*Loss Function*)**.

L'analisi del Ciclo 2 aveva evidenziato una grave asimmetria prestazionale tra le classi. La rete riconosceva agevolmente le targhe (oggetti rigidi e geometricamente definiti) ma falliva nell'identificazione dei volti nel dominio Fisheye (oggetti piccoli e fluidamente deformati ai bordi della lente). Per **contrastare** la naturale "**pigrizia**" della rete **verso la classe minoritaria e più complessa**, sono stati manipolati gli iperparametri della **funzione di Loss** durante il comando di *training* come:

- **Class Loss Gain (cls = 1.5):** il peso associato all'errore di classificazione è stato aumentato a 1.5 (quasi raddoppiato) rispetto allo standard. Questa scelta algoritmica **"punisce" il modello** se scambia o manca un volto rispetto a una targa, forzando i gradienti a ottimizzare l'identificazione della **classe minoritaria e più sfidante**.

Per mantenere la **coerenza scientifica** del confronto con il Ciclo 2, l'addestramento è stato eseguito mantenendo invariata l'infrastruttura di base. È stata utilizzata l'architettura compatta **YOLOv9c** ed è stato applicato il **Transfer Learning** partendo dai pesi pre-addestrati sul dataset globale COCO. Il processo è stato vincolato a un *seed* fisso per garantire la **totale riproducibilità**, impostato su 50 epoche con una dimensione di input (*imgsz*) pari a 640 pixel.

Fase 3: Inferenza e Valutazione delle metriche

Il modello ha stabilito nuovi primati assoluti sulle immagini standard, raggiungendo un'**AP del 92.33% sulle targhe** e del **79.95% sui volti**, con AR prossimi al 90%. Questo dimostra che l'immissione di dati distorti non ha "cancellato" la memoria della prospettiva lineare, ma ha agito da potente regolarizzatore.

Sulla classe "Targa" nel dominio sferico, l'architettura ha registrato un'**AP dell'88.20%** e un'**AR dell'82.73%**, certificando una comprensione geometrica matura delle deformazioni.

Il traguardo più rilevante è il recupero totale sulla classe "Volto" distorta. Passando dal collasso del 43.68% (Ciclo 2) a un solido **66.78% di AP**, il modello non solo ha curato i propri limiti generati dallo sbilanciamento originario, ma ha **battuto formalmente la Baseline originaria (+7.58%)**, ripristinando al contempo un'elevata capacità di identificazione spaziale (**AR al 62.31%**).

8. Risultati Finali: Impatto dell'approccio Data-Centric

Questa tabella illustra l'evoluzione completa delle prestazioni, confrontando il modello originario (Baseline), l'addestramento su un dataset misto sbilanciato (Ciclo 2) e l'addestramento sul dataset aumentato sinteticamente e bilanciato (Ciclo 3).

Dominio e Classe	Metrica	Baseline (YOLOX)	Ciclo 2 ("M-D")	Ciclo 3 ("Data-Centric")	Variazione (C3 vs Baseline)
Normal - "Targa"	AP_0.5	88.12%	91.16%	**92.33%**	**+4.21%**
	AR_0.5	**91.88%**	86.86%	90.52%	**-1.36%**
Normal - "Volto"	AP_0.5	76.22%	77.65%	**79.95%**	**+3.73%**
	AR_0.5	**92.52%**	74.29%	89.97%	**-2.55%**
Fisheye - "Targa"	AP_0.5	49.53%	83.31%	**88.20%**	**+36.67%**
	AR_0.5	58.17%	81.82%	**82.73%**	**+24.56%**
Fisheye - "Volto"	AP_0.5	59.20%	43.68%	**66.78%**	**+7.58%**
	AR_0.5	**63.92%**	38.46%	62.31%	**-1.61%**

L'analisi dei risultati ottenuti nel Ciclo 3 certifica il pieno successo della strategia *Data-Centric* adottata. L'integrazione di immagini sintetiche generate tramite simulazione ottica (*Circular Fisheye*), unita a un bilanciamento esplicito dei pesi della funzione di *loss* durante il training, ha permesso di superare le criticità strutturali emerse nel Ciclo 2, portando l'architettura YOLOv9 a superare la Baseline (YOLOX) in quasi tutte le metriche chiave.

1. Consolidamento sul Dominio Lineare (Normal)

Il primo dato di rilievo è l'assenza di *Catastrophic Forgetting*. Nonostante l'immissione di migliaia di immagini fortemente distorte nel set di addestramento, il modello non ha disimparato la prospettiva lineare. Al contrario, l'AP_0.5 ha registrato nuovi primati assoluti: 92.33% sulle targhe (+4.21% rispetto alla Baseline) e 79.95% sui volti (+3.73%). Particolarmente significativo è il balzo dell'Average Recall (AR) rispetto al Ciclo 2: sui volti lineari, la capacità di recupero è passata dal 74.29% a sfiorare il 90% (89.97%).

Questo dimostra che la *Data Augmentation* sintetica ha agito come un potente regolarizzatore, rendendo l'estrazione delle *feature* più robusta e riducendo drasticamente i falsi negativi che affliggevano il precedente addestramento.

2. Il superamento dei limiti sul Dominio Fisheye

Il dominio sferico rappresenta il vero banco di prova del progetto, e i risultati del Ciclo 3 evidenziano un salto prestazionale netto. Sulla classe "Targa", geometricamente meno complessa, l'AP raggiunge uno sbalorditivo 88.20%, segnando un +38.67% sulla Baseline e migliorando persino l'ottimo risultato del Ciclo 2 (+4.89%). Anche l'AR si consolida all'82.73% (+24.56% vs Baseline).

3. La risoluzione del collasso sulla classe "Volto"

Il risultato più rilevante dell'intero esperimento risiede però nella classe "Volto" sul dominio Fisheye. Nel Ciclo 2, la discrepanza numerica dei domini e la difficoltà geometrica avevano fatto crollare l'AP al 43.68%, ben al di sotto della Baseline (59.20%). Grazie all'approccio *Data-Centric* del Ciclo 3, l'AP sui volti distorti è schizzata al 66.78%, recuperando un +23.10% dal ciclo precedente e, soprattutto, battendo l'architettura YOLOX originaria (+7.58%). Parallelamente, l'AR è balzata dal 38.46% del Ciclo 2 al 62.31%, allineandosi quasi perfettamente ai livelli di targa della Baseline originaria.

Conclusioni

Il presente lavoro nasce per rispondere a un quesito tecnico specifico nel dominio della "Computer Vision" applicata alla guida autonoma: modelli "state-of-the-art" come YOLOv9, sottoposti a un "fine-tuning" strategico, possono eguagliare o superare le metriche di "Average Precision" (AP) e "Average Recall" (AR) di una complessa "baseline" YOLOX, utilizzando esclusivamente la quantità limitata di immagini del dataset PP4AV, senza ricorrere a enormi moli di video esterni o a tecniche di "Knowledge Distillation"?

L'analisi delle metriche estratte al termine dei tre cicli sperimentali permette di formulare una **risposta pienamente affermativa**, validando l'ipotesi di "Data Efficiency".
L'efficienza architetturale di YOLOv9, unita a un'ingegnerizzazione del set di addestramento, ha dimostrato che la **qualità** e la **preparazione del dato possono risolvere i "corner cases"** legati alle distorsioni ottiche ("Fisheye") in un regime di stretta scarsità di dati, compensando e superando ampiamente l'addestramento massivo su fonti esterne.

L'analisi dei risultati ottenuti nel Ciclo 3 certifica il **pieno successo della strategia "Data-Centric"** adottata. L'integrazione di immagini sintetiche generate tramite simulazione ottica ("Circular Fisheye"), unita a un bilanciamento esplicito dei pesi della funzione di "loss" durante il "training", ha permesso di superare le criticità strutturali emerse nel Ciclo 2, portando l'architettura YOLOv9 a superare la "Baseline" (YOLOX) in quasi tutte le metriche chiave.

In conclusione, questo progetto dimostra che nell'era delle architetture neurali ultra-ottimizzate, **la pura potenza del modello non è sufficiente per affrontare i domini visivi estremi**. La vera frontiera per la **risoluzione** dei problemi complessi risiede nella profonda **comprensione**, **manipolazione** e **ingegnerizzazione del dato stesso**.